MIMIC-IV v3.1 통계 분석 보고서

> **분석 일자**: 2026-03-15
> **데이터셋**: MIMIC-IV v3.1 (PhysioNet)
> **분석 대상**: 546,028 입원 건 / 364,627 환자 / 94,458 ICU 체류

목차

1. 데이터 개요
2. 기술통계
3. 상관분석
4. 교호작용 분석
5. 교차분석 & 카이제곱 검정
6. 분포 시각화
7. 종합 요약 및 시사점

1. 데이터 개요

MIMIC-IV는 미국 Beth Israel Deaconess Medical Center(BIDMC)의 전자건강기록(EHR) 데이터셋으로, 2008~2022년 사이의 환자 데이터를 포함합니다.

분석에 사용된 핵심 테이블

테이블	행 수	설명
patients	364,627	환자 기본정보 (성별, 나이)
admissions	546,028	입퇴원 정보, 사망 여부
icustays	94,458	ICU 체류 기록
diagnoses_icd	6,364,488	ICD 진단 코드
drgcodes	761,856	DRG 중증도/사망위험도
labevents	500,000 (샘플)	검사 결과
transfers	2,413,581	전동 기록
services	593,071	진료과 배정

통합 데이터셋 구성

patients + admissions + icustays(첫 ICU) + 진단 수 + DRG severity를 병합하여 **546,028행 x 32열**의 통합 분석 데이터를 구축했습니다.

2. 기술통계

2-1. 수치형 변수 요약

변수	count	mean	std	min	1%	25%	50%	75%	95%	99%	max
age	546,028	56.89	18.97	18	19	43	58	71	86	91	91
los_hospital (일)	546,028	4.76	7.21	-0.95	0.11	1.13	2.82	5.62	15.42	33.92	515.56
los_icu (일)	85,228	3.51	5.17	0.001	0.27	1.09	1.92	3.73	12.09	25.51	159.67
n_diagnoses	546,028	11.66	7.63	0	1	6	10	16	27	36	57
hospital_expire_flag	546,028	0.022	0.145	0	0	0	0	0	0	1	1
drg_severity	366,931	2.43	0.94	1	1	2	2	3	4	4	4
drg_mortality	366,931	2.07	1.03	1	1	1	2	3	4	4	4

2-2. 왜도(Skewness) & 첨도(Kurtosis)

변수	왜도	첨도	평균	중앙값	CV(%)	해석
age	-0.20	-0.84	56.89	58.0	33.3	거의 정규분포, 약간 좌편향
los_hospital	**7.78**	**159.24**	4.76	2.82	151.4	극심한 우편향, 이상치 다수
los_icu	**5.80**	**65.59**	3.51	1.92	147.3	극심한 우편향, 이상치 다수
n_diagnoses	1.02	0.94	11.66	10.0	65.5	약한 우편향
hospital_expire_flag	6.58	41.29	0.022	0.0	672.8	극심한 클래스 불균형 (2.2% 양성)
drg_severity	0.05	-0.90	2.43	2.0	38.7	거의 균등분포
drg_mortality	0.48	-1.00	2.07	2.0	49.6	약한 우편향

> **핵심 인사이트**: los_hospital과 los_icu는 왜도 > 5로 극심한 우편향을 보이므로, 모델링 시 **로그 변환**이나 **이상치 처리**가 필수적입니다.

2-3. 범주형 변수 분포

성별

성별	건수	비율(%)
F (여성)	284,097	52.03
M (남성)	261,931	47.97

입원 유형

입원 유형	건수	비율(%)
EW EMER. (응급)	177,459	32.50
EU OBSERVATION	119,456	21.88
OBSERVATION ADMIT	84,437	15.46
URGENT	54,929	10.06
SURGICAL SAME DAY	42,898	7.86
DIRECT OBSERVATION	24,551	4.50
DIRECT EMER.	21,973	4.02
ELECTIVE	13,130	2.40
AMBULATORY OBS.	7,195	1.32

보험 유형

보험	건수	비율(%)
Medicare	244,576	44.79
Private	173,399	31.76
Medicaid	104,229	19.09
Other	14,006	2.57
No charge	463	0.08

결혼 상태

상태	건수	비율(%)
MARRIED	229,134	41.96
SINGLE	206,232	37.77
WIDOWED	56,687	10.38
DIVORCED	40,356	7.39

인종 (상위 5개)

인종	건수	비율(%)
WHITE	336,538	61.63
BLACK/AFRICAN AMERICAN	75,482	13.82
OTHER	19,788	3.62
WHITE - OTHER EUROPEAN	13,972	2.56

인종	건수	비율(%)
UNKNOWN	13,870	2.54

2-4. 사망 vs 생존 그룹 비교

변수	생존 (n=534,227)		사망 (n=11,801)		t-test
	mean	std	mean	std	p-value
age	56.61	18.95	**69.48**	15.13	p < 0.001 ***
los_hospital	4.65	6.93	**10.01**	14.17	p < 0.001 ***
los_icu	3.30	4.86	**5.17**	6.95	p < 0.001 ***
n_diagnoses	11.42	7.43	**22.24**	9.18	p < 0.001 ***
is_male	0.478	0.50	**0.542**	0.50	p < 0.001 ***

> **핵심 인사이트**: 사망 그룹은 생존 그룹 대비 평균 나이 **+13세**, 재원일수 **2.2배**, 진단 수 **2배**로 모든 변수에서 통계적으로 유의한 차이를 보입니다.

3. 상관분석

3-1. Pearson 상관계수 히트맵

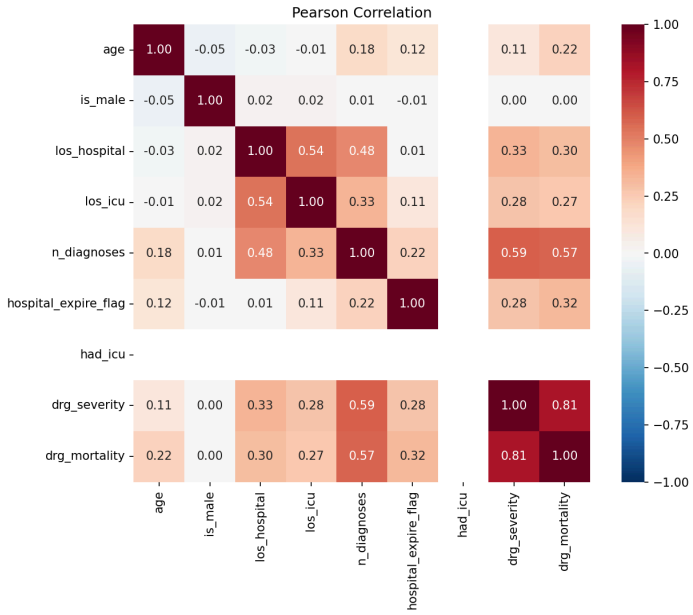

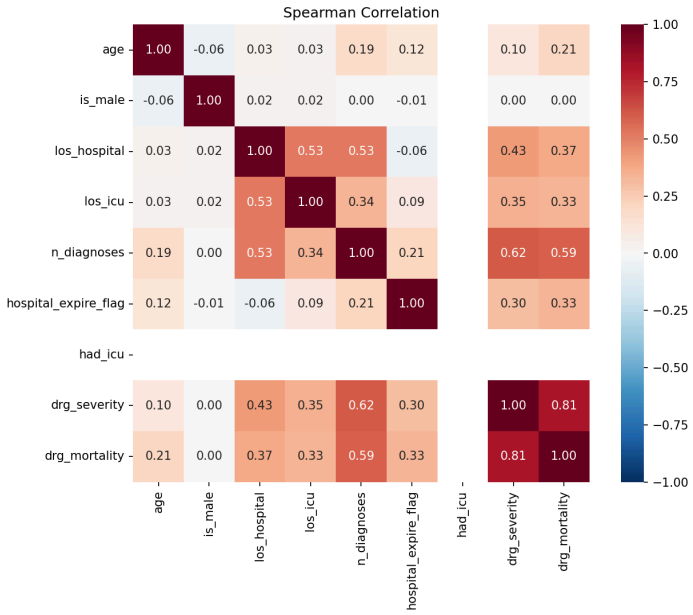

3-2. Pearson 상관계수 행렬

	age	is_male	los_hosp	los_icu	n_diag	expire	drg_sev	drg_mort
age	1.000	-0.051	-0.025	-0.015	0.180	0.121	0.113	0.219

	age	is_male	los_hosp	los_icu	n_diag	expire	drg_sev	drg_mort
is_male	-0.051	1.000	0.019	0.017	0.006	-0.006	0.001	0.002
los_hospital	-0.025	0.019	1.000	**0.535**	**0.476**	0.007	**0.334**	0.299
los_icu	-0.015	0.017	**0.535**	1.000	**0.332**	0.114	0.281	0.266
n_diagnoses	0.180	0.006	**0.476**	**0.332**	1.000	0.222	**0.592**	**0.573**
expire_flag	0.121	-0.006	0.007	0.114	0.222	1.000	0.280	**0.315**
drg_severity	0.113	0.001	**0.334**	0.281	**0.592**	0.280	1.000	**0.808**
drg_mortality	0.219	0.002	0.299	0.266	**0.573**	**0.315**	**0.808**	1.000

3-3. 주요 상관 쌍 (|Pearson r| > 0.3)

변수 1	변수 2	Pearson r	Spearman rho	해석
drg_severity	drg_mortality	**0.808**	0.815	매우 강한 양의 상관 (같은 DRG 체계)
n_diagnoses	drg_severity	**0.592**	0.615	진단 많을수록 중증도 높음
n_diagnoses	drg_mortality	**0.573**	0.589	진단 많을수록 사망위험도 높음
los_hospital	los_icu	**0.535**	0.529	ICU 재원 길면 전체 재원도 길
los_hospital	n_diagnoses	**0.476**	0.525	진단 많을수록 재원 길
los_hospital	drg_severity	**0.334**	0.429	중증도 높을수록 재원 길
los_icu	n_diagnoses	**0.332**	0.336	진단 많을수록 ICU 재원 길
expire_flag	drg_mortality	**0.315**	0.332	DRG 사망위험도와 실제 사망 연관

3-4. Point-Biserial 상관 (사망 vs 연속형 변수)

변수	r_pb	p-value	유의성
n_diagnoses	**+0.206**	p < 0.001	***
los_icu	+0.114	p < 0.001	***
los_hospital	+0.108	p < 0.001	***
age	+0.099	p < 0.001	***

> **핵심 인사이트**: 사망 예측에 가장 강한 단일 변수는 **진단 수(r=0.21)** 이며, DRG severity/mortality 쌍은 r=0.81로 **다중공선성** 위험이 있어 모델 투입 시 하나만 선택하거나 차원 축소가 필요합니다.

4. 교호작용 분석

4-1. 나이 x 성별 -> 사망률

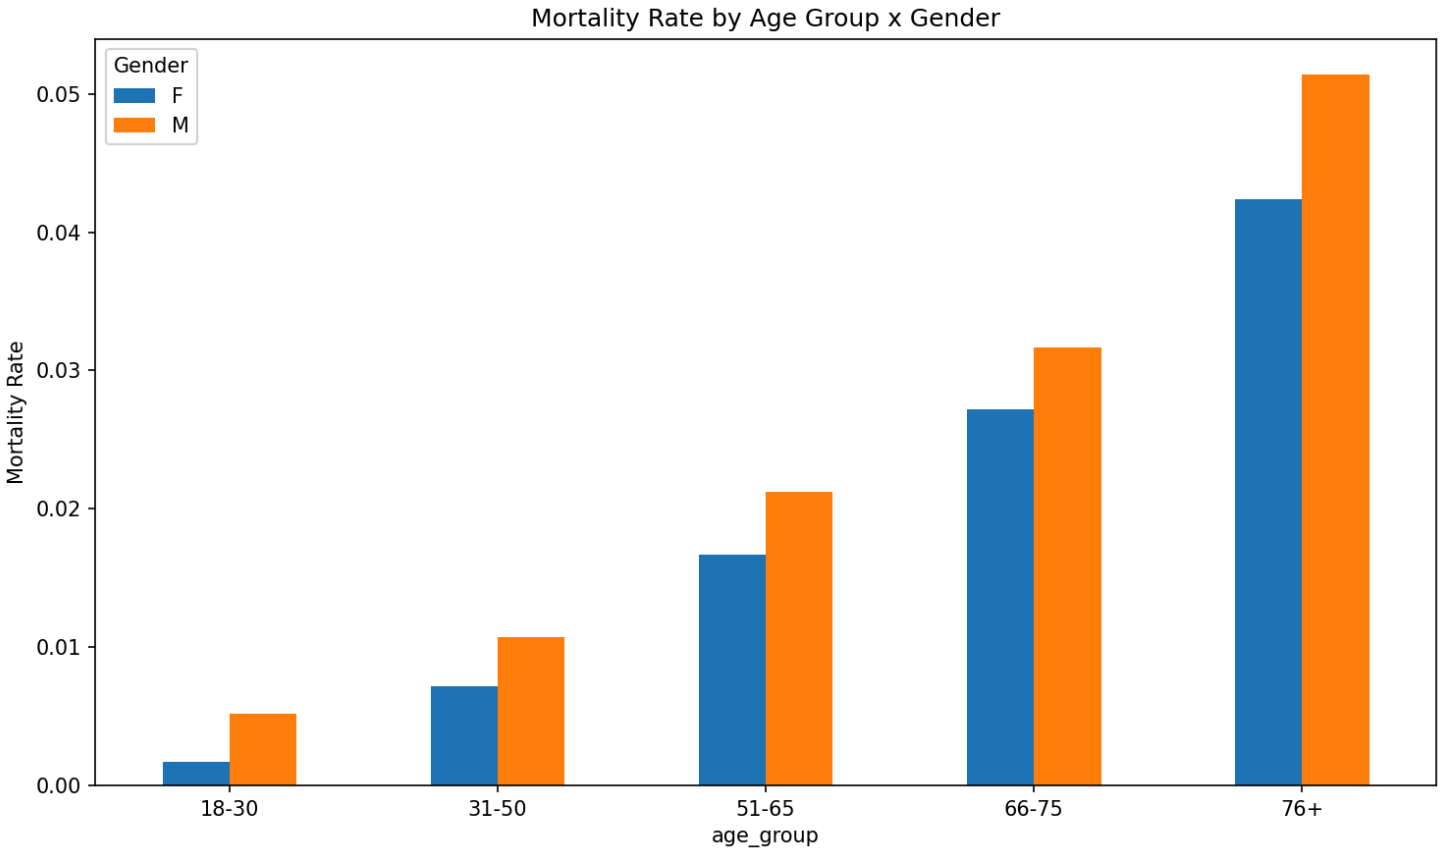

나이 그룹	여성 (n)	여성 사망률	남성 (n)	남성 사망률	차이
18-30	41,082	0.17%	23,946	0.52%	+0.35%p
31-50	68,870	0.72%	59,363	1.07%	+0.35%p
51-65	72,102	1.67%	85,760	2.12%	+0.45%p
66-75	45,211	2.72%	48,485	3.17%	+0.45%p
76+	**56,832**	**4.24%**	**44,377**	**5.14%**	**+0.90%p**

> 모든 연령대에서 남성 사망률이 여성보다 높으며, 고령일수록 성별 격차가 커집니다.

4-2. 보험유형 x ICU 입원 -> 사망률

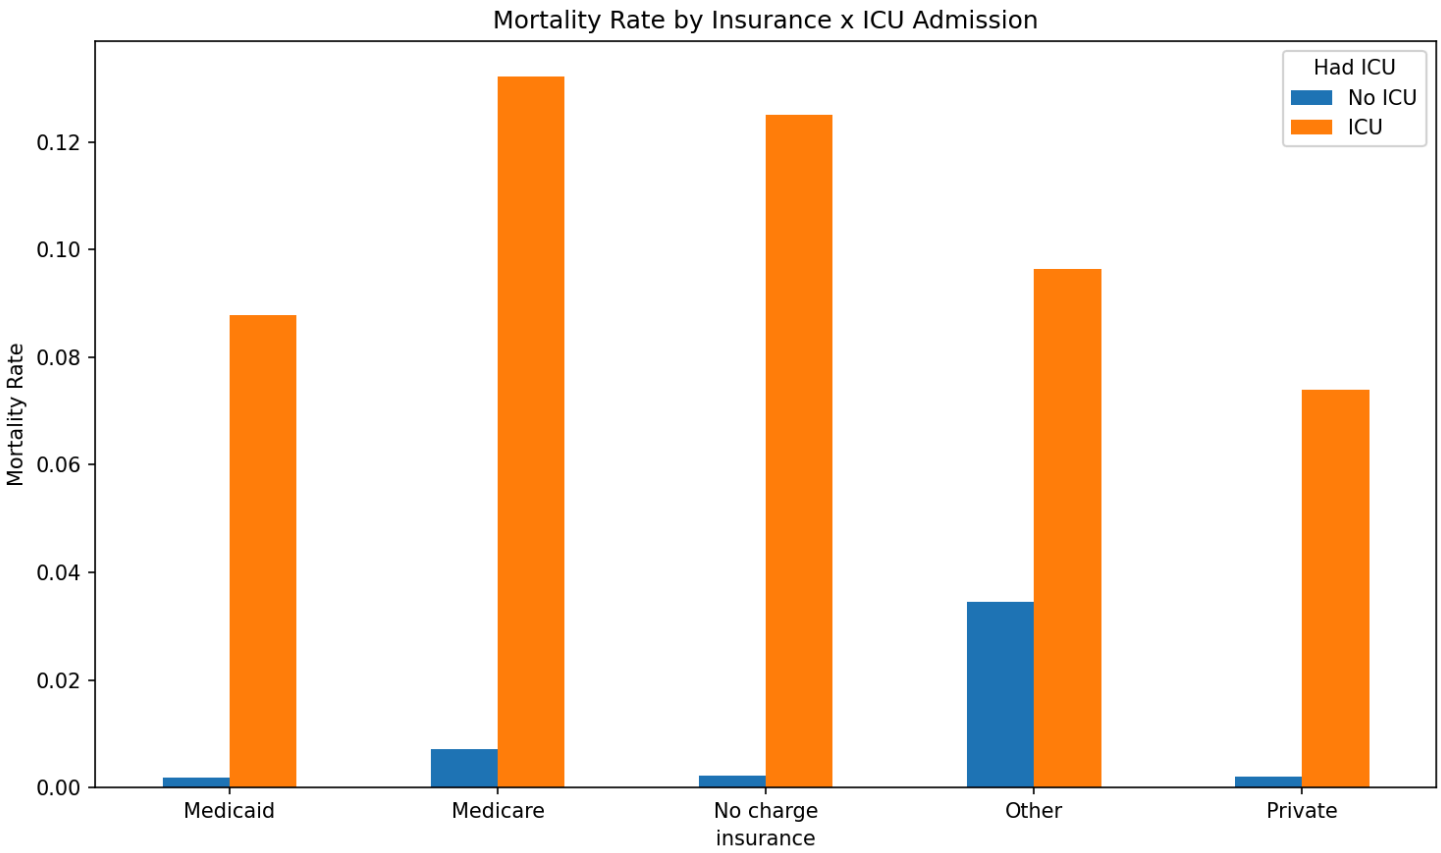

보험	No ICU (n)	No ICU 사망률	ICU (n)	ICU 사망률	배율
Medicaid	91,417	0.18%	12,812	8.79%	x49
Medicare	**197,963**	**0.71%**	**46,613**	**13.22%**	**x19**
Private	151,117	0.21%	22,282	7.40%	x35
Other	11,910	3.46%	2,096	9.64%	x3

> ICU 입원 시 사망률은 비ICU 대비 **3~49배** 증가하며, **Medicare(고령자)** 환자의 ICU 사망률이 13.2%로 가장 높습니다.

4-3. 나이 x 진단 수 -> 사망률

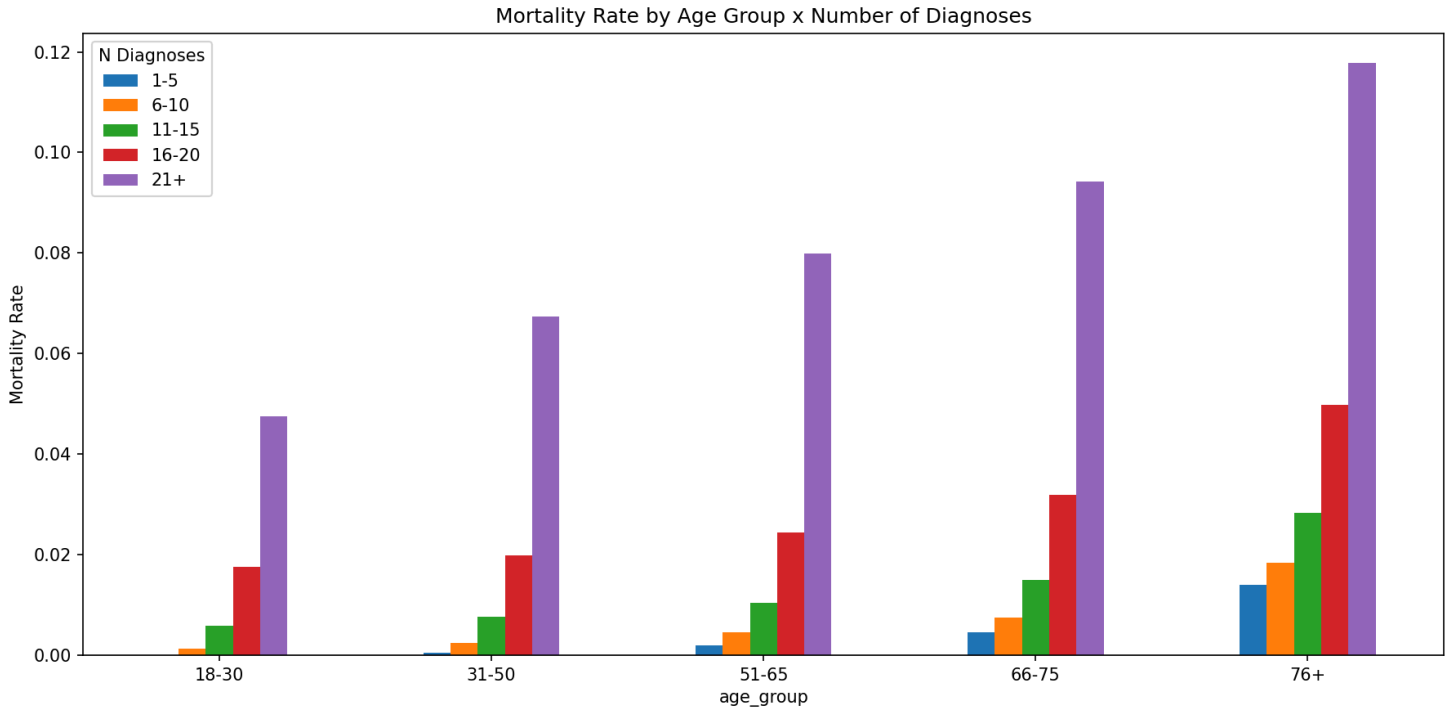

나이 \ 진단 수	1-5	6-10	11-15	16-20	21+
18-30	0.01%	0.13%	0.58%	1.77%	4.76%
31-50	0.06%	0.25%	0.76%	1.99%	6.73%
51-65	0.19%	0.46%	1.05%	2.45%	7.99%
66-75	0.45%	0.76%	1.49%	3.19%	9.42%
76+	**1.40%**	**1.84%**	**2.83%**	**4.98%**	**11.79%**

> 나이와 진단 수의 교호작용이 매우 뚜렷합니다. **76세 이상 + 진단 21개 이상** 그룹의 사망률은 **11.8%** 로, 18-30세 + 진단 1-5개 그룹(0.01%)의 약 **1,180배**입니다.

4-4. 입원유형 x 성별 -> 평균 재원일수

입원유형	여성 avg LOS	남성 avg LOS	남성 median LOS
AMBULATORY OBS.	1.16일	1.08일	0.92일
EU OBSERVATION	1.05일	0.94일	0.67일
DIRECT OBSERVATION	1.34일	1.27일	1.03일
EW EMER.	5.71일	6.10일	3.82일
OBSERVATION ADMIT	6.57일	7.01일	4.69일
ELECTIVE	6.03일	6.53일	4.74일
DIRECT EMER.	7.02일	7.38일	4.93일

입원유형	여성 avg LOS	남성 avg LOS	남성 median LOS
URGENT	**5.89일**	**9.22일**	**6.04일**

> **URGENT 입원**에서 남성의 평균 재원일수(9.22일)가 여성(5.89일)보다 **1.57배** 길어 가장 큰 성별 격차를 보입니다.

4-5. ICU 유닛 x 나이 -> 사망률 (상위 7개 유닛)

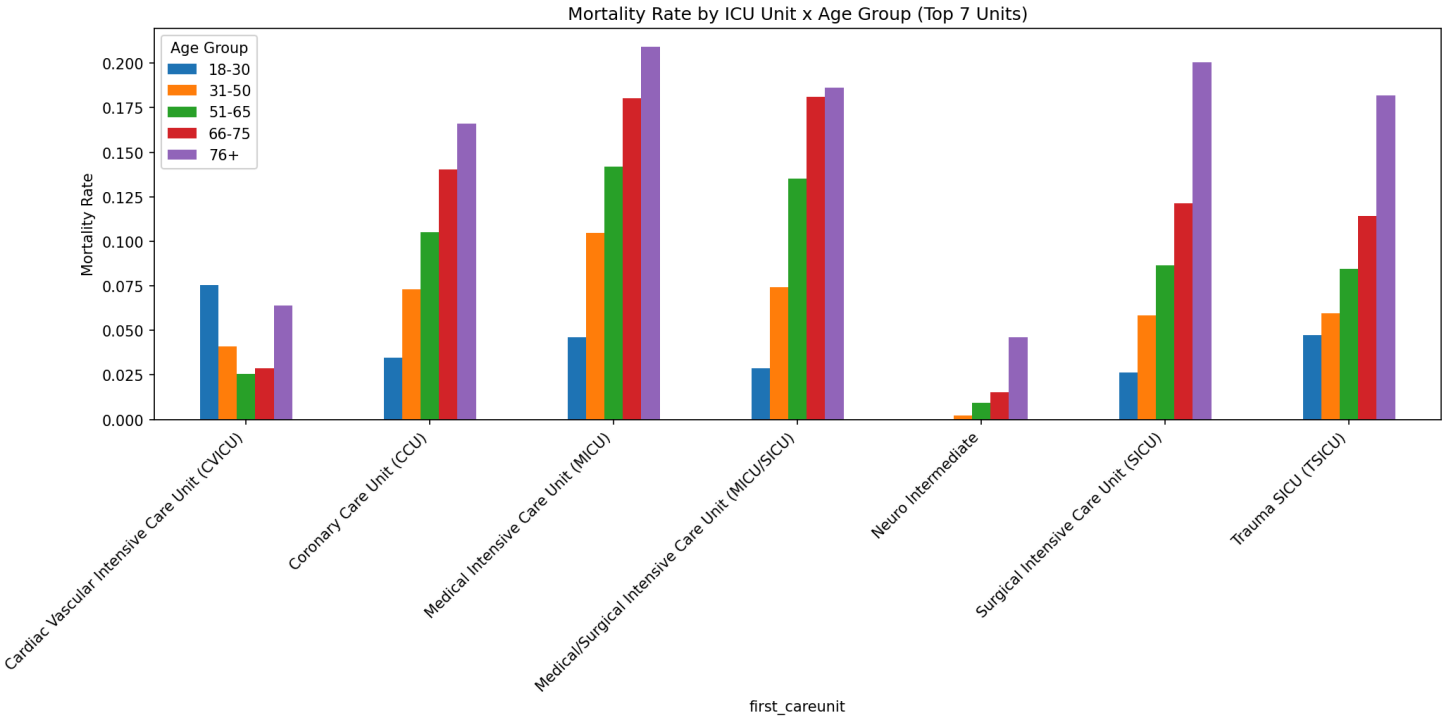

ICU 유닛	18-30	31-50	51-65	66-75	76+
CVICU	7.6%	4.1%	2.5%	2.9%	6.4%
CCU	3.5%	7.3%	10.5%	14.0%	16.6%
MICU	**4.6%**	**10.5%**	**14.2%**	**18.0%**	**20.9%**
MICU/SICU	2.9%	7.4%	13.5%	18.1%	18.6%
Neuro Inter.	0.0%	0.2%	1.0%	1.5%	4.6%
SICU	2.6%	5.9%	8.7%	12.1%	20.1%
TSICU	4.7%	6.0%	8.5%	11.4%	18.2%

> **MICU(내과 중환자실)** 76세 이상에서 사망률 **20.9%** 로 전 유닛 중 최고이며, **Neuro Intermediate**는 전 연령대에서 가장 낮은 사망률을 보입니다. CVICU는 특이하게 중간 연령대(51-65세)에서 오히려 사망률이 가장 낮은 U자형 패턴을 보입니다.

5. 교차분석 & 카이제곱 검정

모든 검정에서 **p < 0.001 (***)**로 통계적으로 유의합니다.

변수 1	변수 2	Chi-squared	dof	p-value	Cramer's V	효과 크기
admission_type	**expire_flag**	**7,331.03**	8	< 0.001	**0.116**	약한~중간
insurance	had_icu	4,152.40	4	< 0.001	0.088	약한
insurance	expire_flag	2,658.83	4	< 0.001	0.070	약한
gender	had_icu	2,453.25	1	< 0.001	0.067	약한
marital_status	expire_flag	1,213.14	3	< 0.001	0.048	약한
gender	expire_flag	188.76	1	< 0.001	0.019	매우 약한

입원유형별 사망률 (가장 강한 연관)

입원유형	생존 비율	사망 비율
AMBULATORY OBS.	99.99%	0.01%
EU OBSERVATION	99.91%	0.09%
DIRECT OBSERVATION	99.88%	0.12%
SURGICAL SAME DAY	99.65%	0.35%
ELECTIVE	99.28%	0.72%
OBSERVATION ADMIT	97.82%	2.18%
DIRECT EMER.	97.80%	2.20%
EW EMER.	96.25%	**3.75%**
URGENT	95.55%	**4.45%**

> **URGENT**(4.45%)와 **EW EMER.**(3.75%) 입원이 가장 높은 사망률을 보이며, AMBULATORY OBSERVATION(0.01%)과 약 **445배** 차이입니다.

6. 분포 시각화

6-1. 주요 수치형 변수 분포

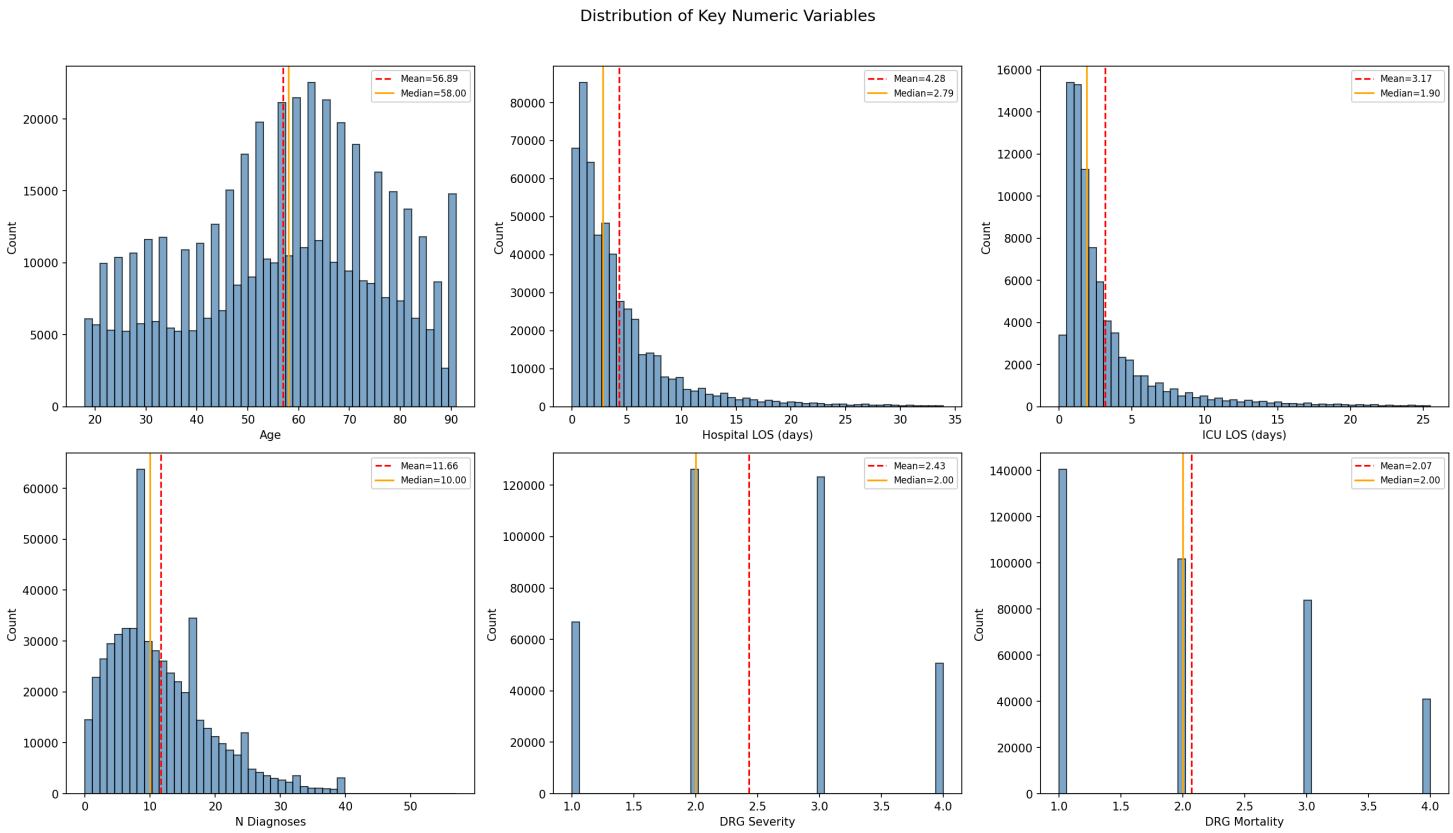

- **Age**: 거의 균등분포, 18세(성인 기준)에서 91세까지
- **Hospital LOS / ICU LOS**: 극심한 우편향, 대부분 짧은 재원 + 소수 장기 재원
- **N Diagnoses**: 약한 우편향, 10개 전후가 가장 빈번
- **DRG Severity / Mortality**: 1~4 범위의 순서형 변수

6-2. 사망 여부별 Boxplot

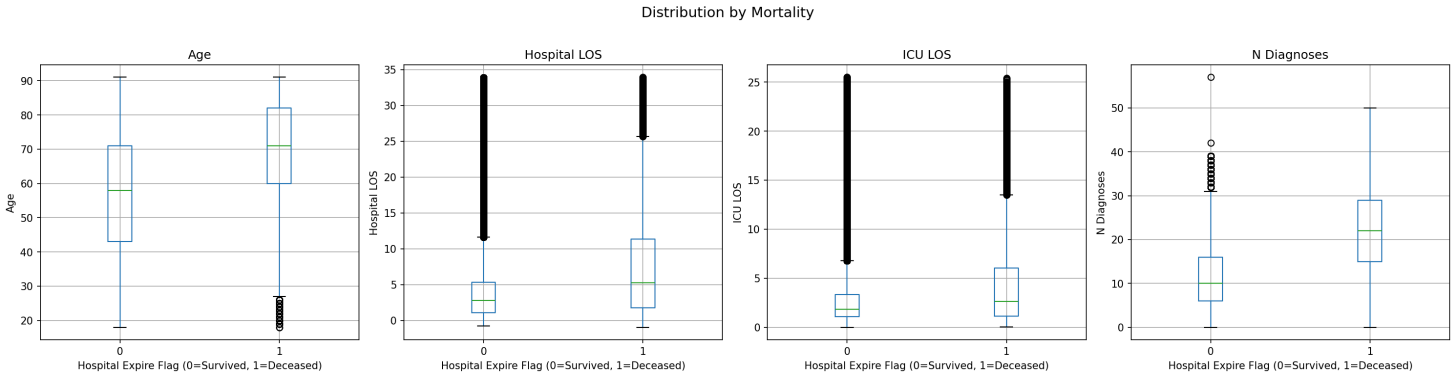

사망 그룹(1)은 생존 그룹(0) 대비 모든 변수에서 중앙값과 분포 범위가 뚜렷하게 높습니다.

6-3. 나이 vs 재원일수 산점도

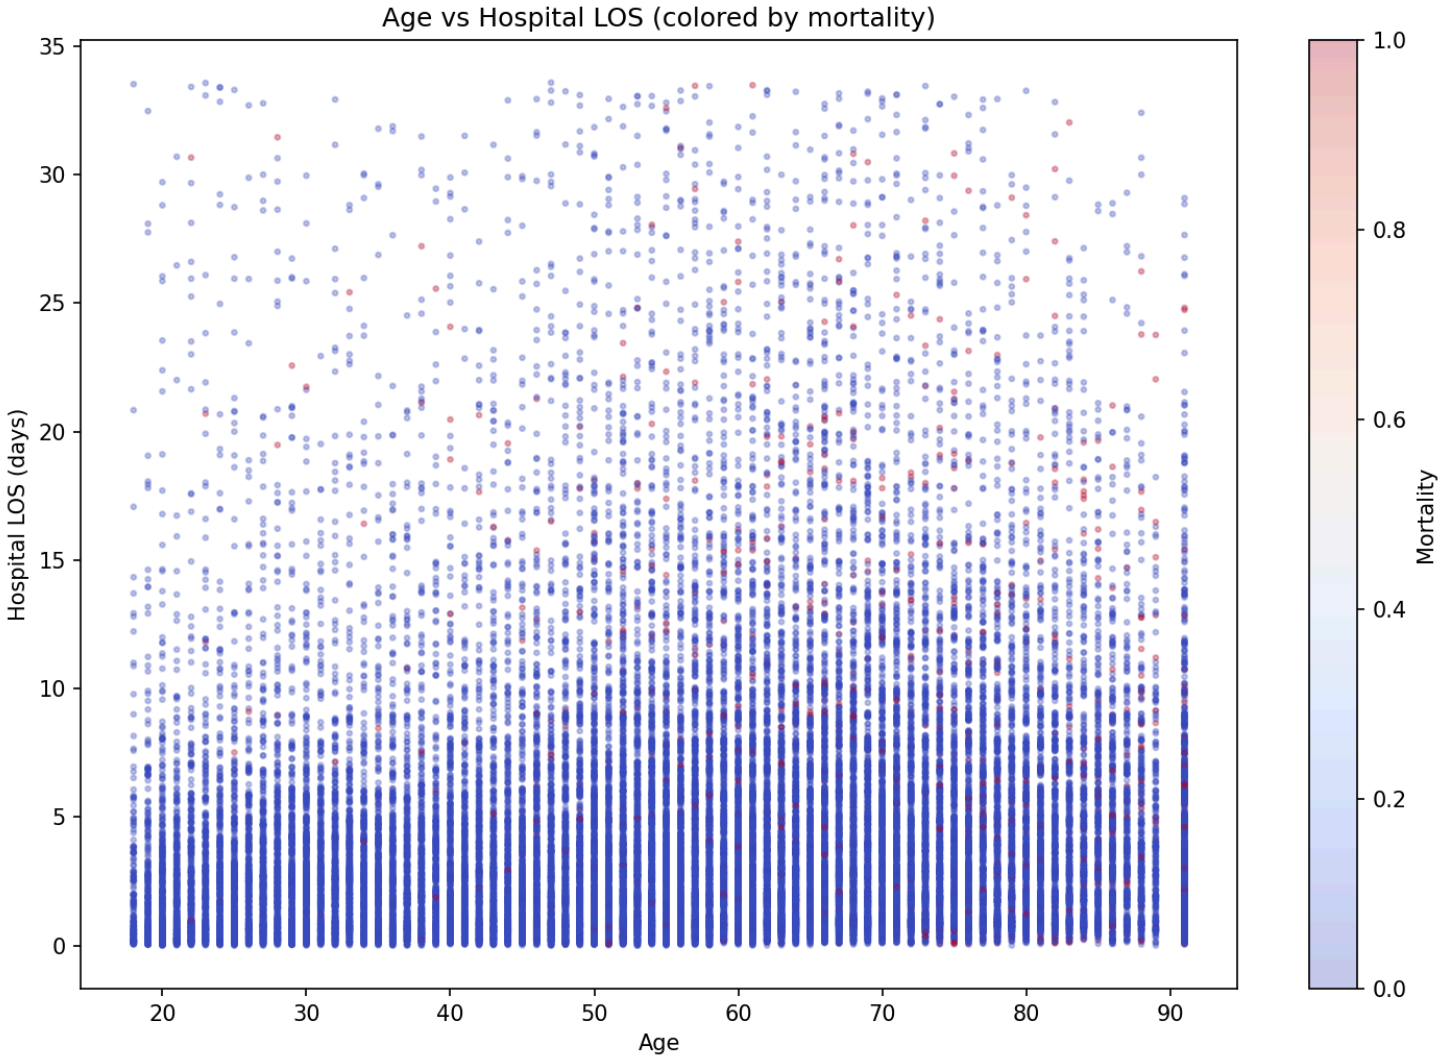

빨간 점(사망)이 고령 + 장기 재원 영역에 집중되어 있음을 확인할 수 있습니다.

7. 종합 요약 및 시사점

주요 발견사항

1. **사망률 2.2%** (11,801 / 546,028) — 심한 클래스 불균형으로 FL 학습 시 **oversampling/loss weighting** 필요
2. **재원일수(LOS)** 는 왜도 > 5로 극심한 우편향 — **로그 변환** 또는 **범주화** 권장
3. **진단 수**가 사망 예측에 가장 강한 단일 예측 변수 (r_pb = 0.21)
4. **DRG severity와 mortality는 r=0.81로 다중공선성** — 둘 중 하나만 사용 권장
5. 나이 x 진단 수 교호작용이 매우 강력 — **76세+ & 진단 21개+** 그룹 사망률 11.8%

FL(Federated Learning) 실험을 위한 제안

항목	제안
타겟 변수	`hospital_expire_flag` (사망 예측) 또는 `los_hospital` (재원일수 예측)

항목	제안
파티셔닝 기준	`first_careunit` (17개 ICU 유닛) — 자연스러운 병원 부서 분산
대안 파티셔닝	`insurance` (5개) — 데이터 heterogeneity 실험에 적합
피처 후보	age, gender, admission_type, insurance, n_diagnoses, drg_severity, had_icu
전처리 주의	LOS 로그변환, 클래스 불균형 처리, DRG 다중공선성 제거

부록: 생성 파일 목록

파일명	유형	설명
`descriptive_stats.csv`	CSV	수치형 변수 기술통계
`skew_kurtosis.csv`	CSV	왜도, 첨도, CV
`pearson_correlation.csv`	CSV	Pearson 상관계수 행렬
`spearman_correlation.csv`	CSV	Spearman 상관계수 행렬
`chi2_tests.csv`	CSV	카이제곱 검정 결과
`interaction_age_gender.csv`	CSV	나이 x 성별 교호작용
`interaction_insurance_icu.csv`	CSV	보험 x ICU 교호작용
`interaction_age_diagnoses.csv`	CSV	나이 x 진단 수 교호작용
`interaction_admtype_gender.csv`	CSV	입원유형 x 성별 교호작용
`interaction_icu_unit_age.csv`	CSV	ICU 유닛 x 나이 교호작용
`correlation_heatmap.png`	이미지	상관계수 히트맵
`interaction_age_gender.png`	이미지	나이 x 성별 사망률 차트
`interaction_insurance_icu.png`	이미지	보험 x ICU 사망률 차트
`interaction_age_diagnoses.png`	이미지	나이 x 진단 수 사망률 차트
`interaction_icu_unit_age.png`	이미지	ICU 유닛 x 나이 사망률 차트
`distributions.png`	이미지	변수 분포 히스토그램
`boxplot_by_mortality.png`	이미지	사망 여부별 Boxplot
`scatter_age_los.png`	이미지	나이 vs 재원일수 산점도