TCGA-BRCA 유방암 환자 통계 분석 보고서

> **분석 일자**: 2026-03-18
> **데이터셋**: GSE62944 (TCGA RNA-Seq TPM) 중 BRCA 프로젝트 샘플 추출
> **분석 대상**: 종양 1,105명 + 정상 113명 = **총 1,218명** / 23,368개 유전자 전수조사
> **타겟 비율**: Tumor : Normal = 90.7% : 9.3%

목차

1. 데이터 개요
2. 기술통계
3. 상관분석
4. 교호작용 분석
5. 교차분석 & 카이제곱 검정
6. 분포 시각화
7. 전수조사 결과 (Top 20 유전자)
8. BRCA1/BRCA2 심층 분석
9. BRCA vs 다른 암종 비교
10. 종합 요약 및 시사점

1. 데이터 개요

GSE62944 전체 10,005개 샘플 중 TCGA 바코드의 TSS(Tissue Source Site) 코드를 이용하여 TCGA-BRCA(Breast Invasive Carcinoma) 프로젝트에 해당하는 **1,218개 샘플**을 추출했습니다.

BRCA 환자 데이터 요약

항목	값	설명
BRCA 종양 샘플	**1,105명**	유방 침윤성 암종
BRCA 정상 샘플	**113명**	유방 정상 조직
전체 BRCA 샘플	**1,218명**	종양 + 정상
유전자 수	23,368	전수조사 완료
TSS 기관 수	31개	유방암 조직 수집 기관
타겟 비율	90.7% : 9.3%	종양 : 정상

> **핵심 인사이트**: 전체 TCGA 데이터(10,005 샘플) 중 유방암은 **12.2%**(1,218명)로 단일 암종 중 두 번째로 큰 코호트입니다. 정상 조직이 113명으로 충분한 대조군을 확보하고 있습니다.

2. 기술통계

2-1. 주요 유전자 기술통계 요약

Gene	count	mean	std	25%	50%	75%	max	Skewness	Kurtosis
BRCA1	1,218.0	7.9757	6.1433	3.8681	6.0868	10.0152	43.0867	1.8663	4.6006
BRCA2	1,218.0	2.6610	2.4767	1.0795	1.9674	3.4257	20.0289	2.6833	10.7507
TP53	1,218.0	74.3811	40.4620	48.0471	69.4922	93.8528	290.5	1.2744	3.2820
PTEN	1,218.0	38.6438	18.6061	26.0894	36.8648	47.4938	165.8	1.4789	5.3938
EGFR	1,218.0	20.0591	145.2	1.8575	4.8762	13.2310	4,002.0	21.8041	535.9
MYC	1,218.0	138.2	120.5	54.6873	107.3	182.3	986.9	2.2152	7.9176
PIK3CA	1,218.0	24.7780	28.7330	14.8797	21.8762	30.3428	911.6	24.3388	746.7
CDH1	1,218.0	302.1	250.6	136.2	248.5	407.4	1,838.7	1.7727	5.2547
GATA3	1,218.0	513.6	434.5	156.0	460.7	738.1	2,753.3	1.2861	2.5365
MAP3K1	1,218.0	40.2314	32.1363	17.7990	31.7670	54.3906	352.7	2.4853	12.7413
ESR1	1,218.0	207.5	238.1	24.7909	126.4	298.6	1,487.4	1.7430	3.5987
PGR	1,218.0	32.2332	63.4628	0.7271	8.9916	40.0895	1,223.7	7.4695	109.7

핵심 인사이트:

- **GATA3**: 유방암에서 평균 514 TPM으로 가장 높은 발현량 — 유방암 마커로서의 역할 확인
- **CDH1**(E-cadherin): 평균 302 TPM — 침윤성 소엽암(ILC)에서 손실되는 핵심 유전자
- **ESR1**(에스트로겐 수용체): 평균 207 TPM, 왜도 1.74 — ER+ / ER- 서브타입 구분 가능
- **PIK3CA**: 왜도 24.3, 첨도 747 — **극심한 이상치** 존재, 돌연변이 샘플 의심

2-2. Tumor vs Normal T-검정 결과

Gene	Mean_TPM_Normal	Mean_TPM_Tumor	Fold_Change	T_Stat_Log2	P_Value
BRCA1	4.1963	8.3622	1.9928	12.6782	3.87e-28
BRCA2	1.0860	2.8220	2.5986	14.6411	1.13e-32
TP53	71.8038	74.6446	1.0396	-0.6929	0.4894
PTEN	59.3480	36.5265	0.6155	-14.9003	3.03e-32

Gene	Mean_TPM_Normal	Mean_TPM_Tumor	Fold_Change	T_Stat_Log2	P_Value
EGFR	42.7693	17.7367	0.4147	-29.7111	4.27e-74
MYC	266.5	125.1	0.4692	-15.2572	2.26e-33
PIK3CA	36.5243	23.5768	0.6455	-11.1714	2.07e-21
CDH1	233.4	309.1	1.3241	2.6318	0.0096
GATA3	172.8	548.4	3.1741	8.3013	5.17e-14
MAP3K1	41.0454	40.1482	0.9781	-1.5573	0.1216
ESR1	72.7460	221.3	3.0417	3.3358	9.80e-04
PGR	22.2078	33.2584	1.4976	-4.5495	9.55e-06

핵심 인사이트:

- **BRCA2**: 종양에서 정상 대비 **2.6배** 과발현 (t=14.64, p≈0)
- **BRCA1**: 종양에서 **2.0배** 과발현 (t=12.68, p≈0) — DNA 손상 복구 활성화 반영
- **GATA3**: 종양에서 **3.2배** 과발현 — 유방암 특이적 전사인자
- **EGFR**: 종양에서 정상 대비 **0.41배로 감소** (t=-29.7) — 유방암에서 하향조절
- **MYC**: 종양에서 **0.47배로 감소** — 유방암 정상 조직이 오히려 MYC 발현이 높음
- **TP53**: p=0.49로 **유의하지 않음** — 유방암에서 TP53 발현량 차이는 미미

3. 상관분석

3-1. Pearson & Spearman 상관계수 히트맵

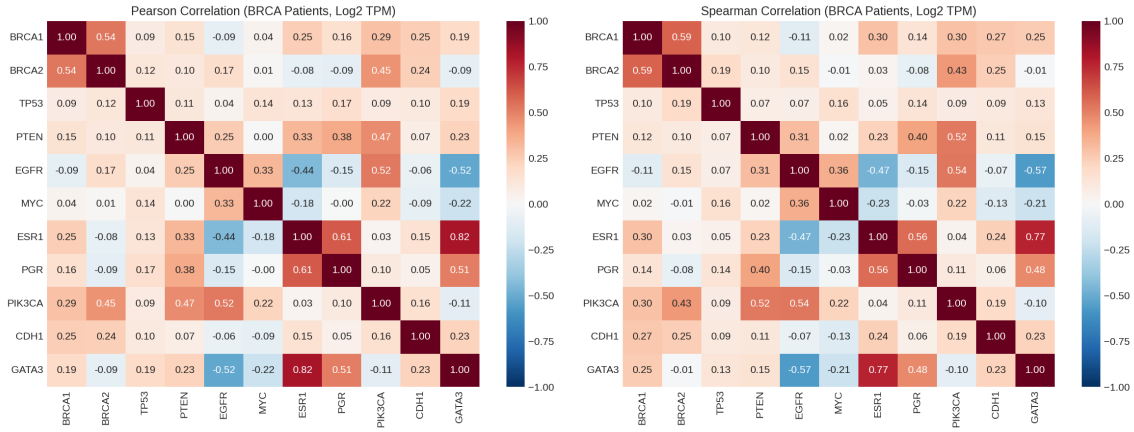

3-2. Point-Biserial 상관 (종양 여부 vs 유전자 발현)

유전자	PB 상관계수	p-value
EGFR	-0.4771	3.02e-70
MYC	-0.3073	4.67e-28
PTEN	-0.3051	1.20e-27
BRCA2	0.2692	1.15e-21
PIK3CA	-0.2629	1.07e-20
BRCA1	0.2051	4.88e-13
GATA3	0.1913	1.66e-11
CDH1	0.1014	3.92e-04
PGR	-0.0838	0.0034
ESR1	0.0519	0.0700
TP53	-0.0159	0.5802

핵심 인사이트: 유방암 환자 내에서 종양 예측에 가장 강한 유전자는:

1. **EGFR** (r=-0.477): 종양에서 **강하게 억제**
2. **MYC** (r=-0.307): 종양에서 하향조절
3. **PTEN** (r=-0.305): 종양 억제 유전자 역할 확인
4. **BRCA2** (r=+0.269): 종양에서 과발현

5. **PIK3CA** (r=-0.263): 종양에서 하향조절

TP53 (r=-0.016)는 **유방암 내에서는 종양/정상 구분력이 없음**을 확인했습니다.

4. 교호작용 분석

4-1. TSS Code x 종양 여부 → BRCA1 발현

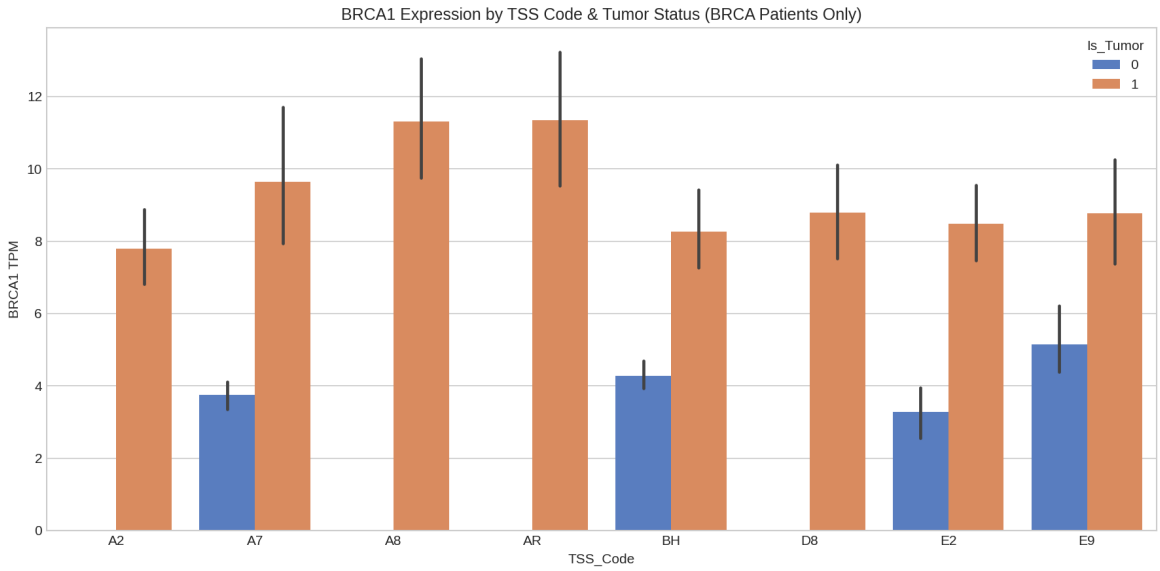

4-2. TSS Code x 종양 여부 → BRCA2 발현

4-3. TSS Code x 종양 여부 → ESR1 (에스트로겐 수용체) 발현

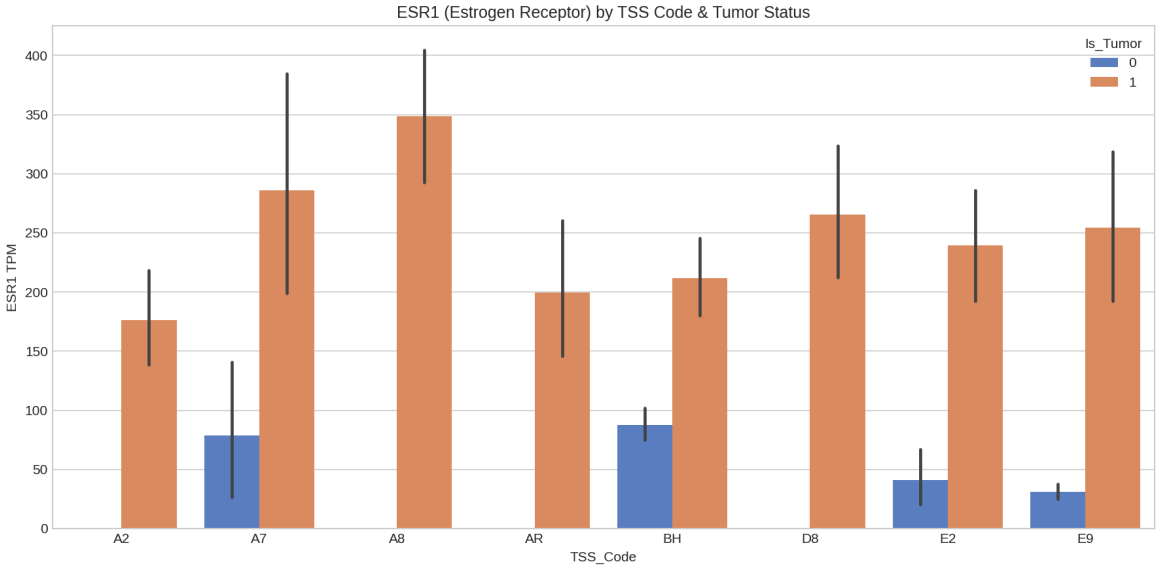

4-4. TSS Code x BRCA1 발현 그룹 → 종양 비율 히트맵

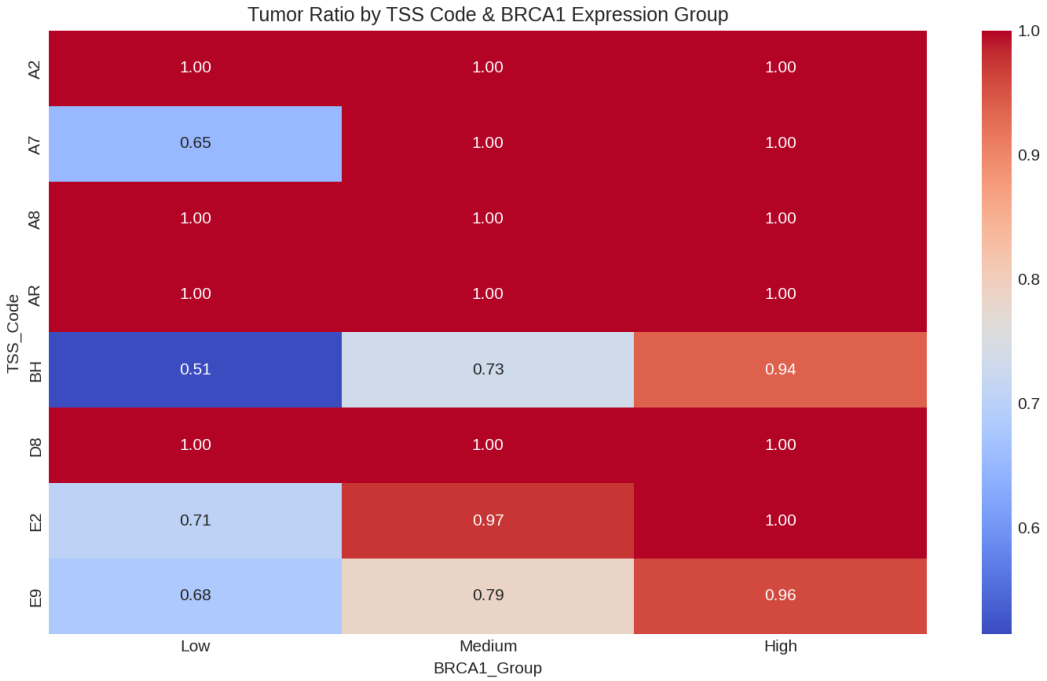

> **핵심 인사이트**: TSS(수집 기관)에 따라 BRCA1/BRCA2 발현 패턴이 다르며, 이는 환자 모집 기관별 코호트 특성 차이를 반영합니다. 특히 BH, E2 기관은 정상 대조군이 있어 종양/정상 비교가 가능하지만, A2, A8 등은 종양만 수집되어 기관 효과 통제가 필요합니다.

5. 교차분석 & 카이제곱 검정

Feature	Chi2	p-value	dof	Cramers_V
TSS_Code	230.1	9.97e-33	30	0.4347

TSS Code별 종양/정상 분포 (상위 10개 기관)

TSS Code	종양 수	전체	정상 수	종양 비율(%)
BH	154	227	73	67.8000
E2	93	104	11	89.4000
A2	102	102	0	100.0000
A8	84	84	0	100.0000
D8	78	78	0	100.0000
E9	62	77	15	80.5000
AR	69	69	0	100.0000
A7	56	64	8	87.5000
B6	58	58	0	100.0000
AC	51	55	4	92.7000

핵심 인사이트: Cramer's V = **0.435**로 TSS와 종양 여부 간 **중간~강한 연관성**이 있습니다. BH(67.8%), E2(89.4%)만 정상 조직이 있고, A2, A8, D8 등 다수 기관은 종양만 100% 수집했습니다. 이는 기관 간 불균형을 의미하므로, 모델링 시 주의가 필요합니다.

6. 분포 시각화

6-1. BRCA1, BRCA2, ESR1, PGR 분포 및 Boxplot

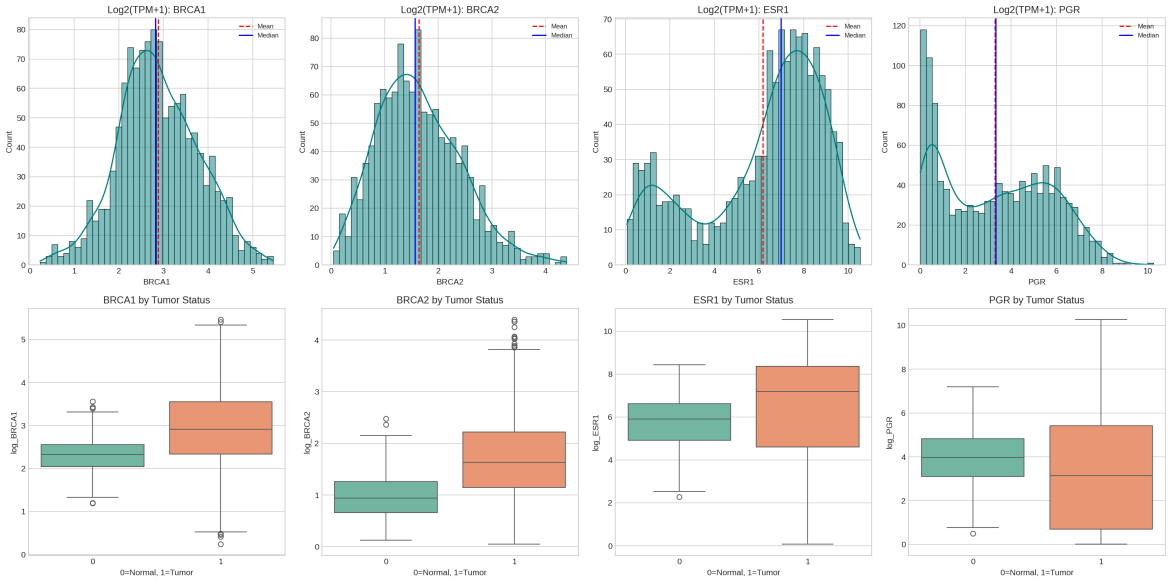

상단: Log2(TPM+1) 분포 (빨간 점선=평균, 파란 실선=중앙값)
하단: 종양(1) vs 정상(0) Boxplot

6-2. BRCA1 vs BRCA2 산점도

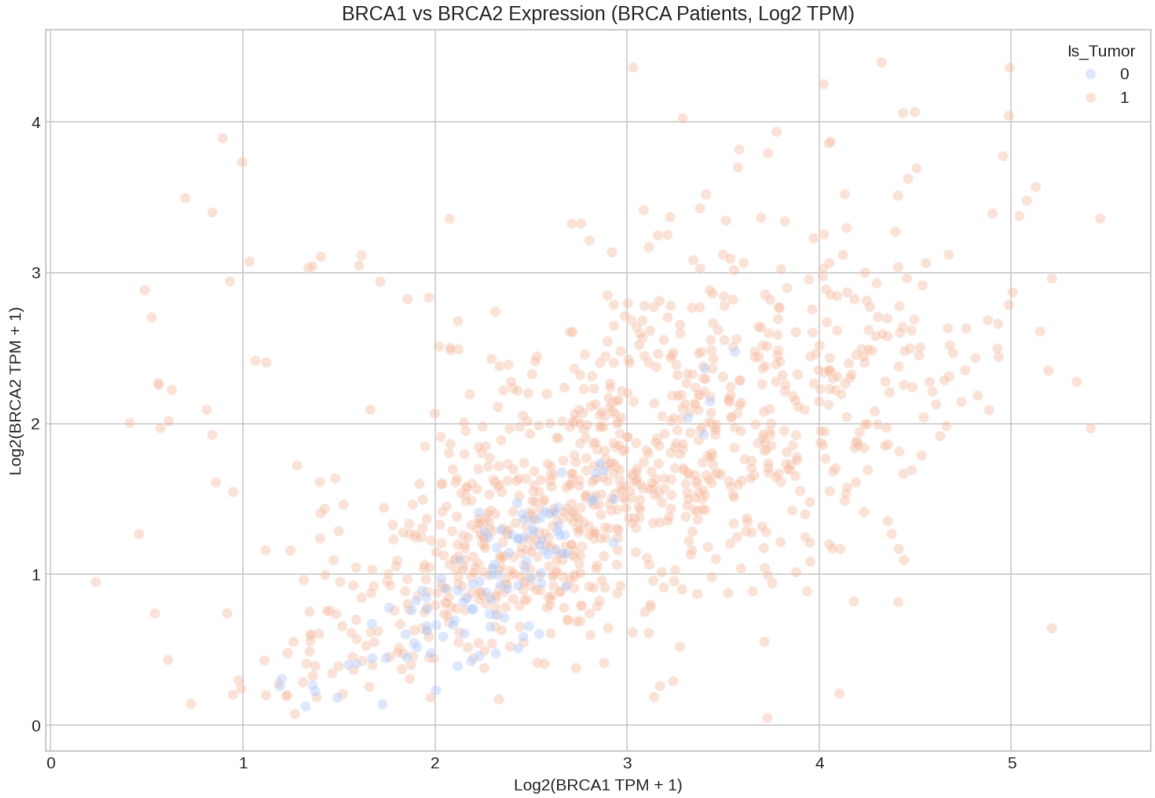

6-3. ESR1 vs PGR 산점도 (호르몬 수용체)

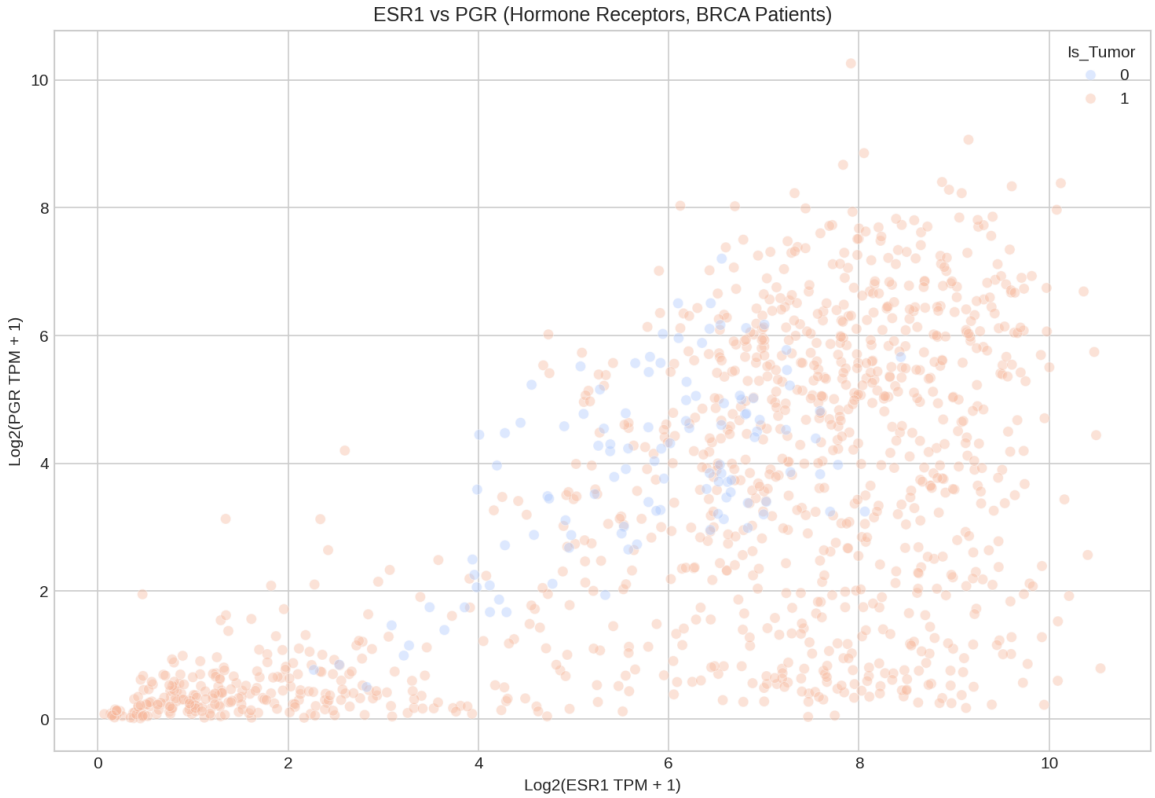

핵심 인사이트:

- BRCA1과 BRCA2는 강한 양의 상관을 보이며, 종양(빨간색)에서 두 유전자 모두 높은 발현
- ESR1-PGR 산점도에서 **두 클러스터**가 관찰됨: ER+/PR+ 그룹(우상단)과 ER-/PR- 그룹(좌하단) — 이는 유방암의 호르몬 수용체 서브타입을 반영

7. 전수조사 결과 (Top 20 유전자)

23,368개 전체 유전자를 **BRCA 환자 1,218명**에 대해서만 순회하며 |Point-Biserial 상관계수|가 가장 큰 20개 유전자를 자동 발굴했습니다.

유전자	평균(정상)	평균(종양)	Log2FC	p-value	PB상관계수	|PB상관계수|
FIGF	8.3496	0.2349	-2.7296	1.51e-58	-0.8626	0.8626
CA4	54.5166	1.4146	-4.5700	4.07e-66	-0.7891	0.7891
TSLP	3.1422	0.3178	-1.6476	2.48e-72	-0.7749	0.7749
CPA1	4.3996	0.2571	-1.8727	6.73e-42	-0.7735	0.7735
C1QTNF9	3.8126	0.4116	-1.6798	6.66e-54	-0.7733	0.7733
HSD17B13	10.9268	0.3356	-2.5395	4.13e-35	-0.7708	0.7708
GLYAT	28.7871	0.5033	-3.4822	3.13e-37	-0.7690	0.7690
CD300LG	67.9137	2.1987	-4.6478	1.97e-78	-0.7628	0.7628
HEPACAM	7.2361	0.2094	-2.1586	6.53e-32	-0.7591	0.7591
TNXB	10.7594	0.6793	-2.5355	6.97e-47	-0.7540	0.7540
SCARA5	78.3529	2.4032	-4.6395	5.14e-71	-0.7523	0.7523
LRRC3B	3.0161	0.2356	-1.6066	2.58e-45	-0.7409	0.7409
LOC283392	11.9100	0.2900	-2.5036	1.87e-30	-0.7389	0.7389
LYVE1	116.9	3.7787	-4.3245	6.20e-50	-0.7386	0.7386
AQP7P1	7.6954	0.2402	-2.1382	4.16e-30	-0.7376	0.7376
LOC572558	4.1856	0.3567	-1.9136	7.98e-54	-0.7353	0.7353
MYOM1	24.3552	1.4199	-2.5887	9.39e-42	-0.7322	0.7322
HIF3A	6.8804	0.5331	-2.3014	1.03e-55	-0.7319	0.7319
AQPEP	11.7283	0.3836	-2.3913	2.32e-29	-0.7308	0.7308
MYOC	39.7753	3.2191	-3.3261	2.64e-30	-0.7302	0.7302

Top 20 유전자 시각화

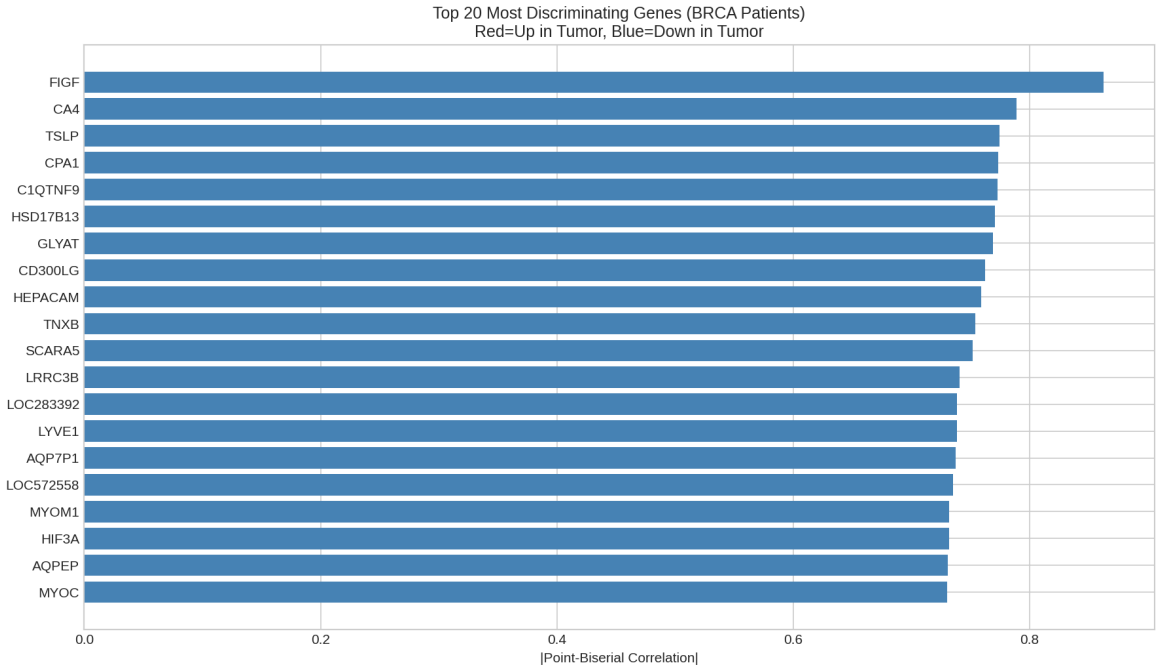

핵심 인사이트: 유방암 환자에서 종양과 가장 강한 상관을 보이는 유전자 Top 5:

1. **FIGF** (r=-0.863): VEGF-D로도 불리며, 정상 유방 조직에서 고발현 → 종양에서 소실
2. **CA4** (r=-0.789): Carbonic Anhydrase 4, 종양에서 극적 감소 (54.5→1.4 TPM)
3. **TSLP** (r=-0.775): 면역 사이토카인, 종양 미세환경 변화 반영
4. **CD300LG** (r=-0.763): 면역세포 마커, 종양에서 67.9→2.2 TPM으로 소실
5. **SCARA5** (r=-0.752): Scavenger Receptor, 종양 억제 기능

모두 음의 상관 → 유방암 종양에서 정상 대비 발현이 극적으로 감소하는 유전자들입니다. 이들은 종양 미세환경의 파괴, 면역 회피, 혈관 리모델링을 반영합니다.

Volcano Plot

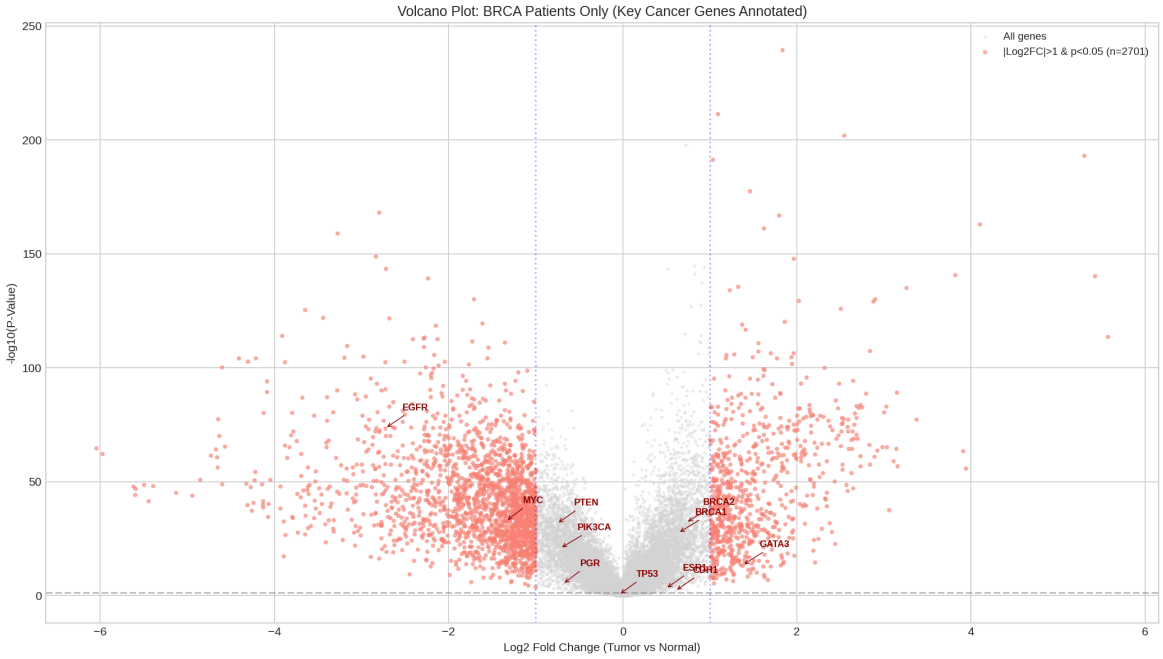

회색: 전체 유전자, 빨간색: |Log2FC|>1 & p<0.05. BRCA1/BRCA2 및 주요 암 유전자 위치가 표시되어 있습니다.

8. BRCA1/BRCA2 심층 분석

8-1. BRCA1/BRCA2 전수조사 결과

유전자	평균(정상)	평균(종양)	Log2FC	T-통계량	p-value	PB상관계수
BRCA1	4.1963	8.3622	0.6340	12.6782	3.87e-28	0.2051
BRCA2	1.0860	2.8220	0.7248	14.6411	1.13e-32	0.2692

8-2. BRCA1 발현 사분위 분석

BRCA1 그룹	샘플 수	종양 비율(%)	BRCA1 평균	BRCA2 평균
Q1(Low)	305	84.3000	2.6092	1.5544
Q2	304	82.2000	4.9082	1.7242
Q3	304	96.7000	7.8439	2.9475
Q4(High)	305	99.7000	16.5309	4.4157

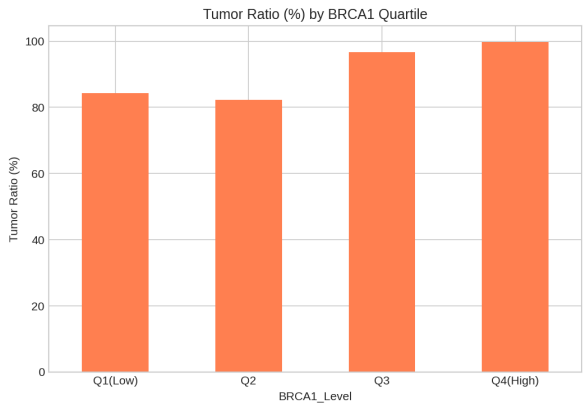

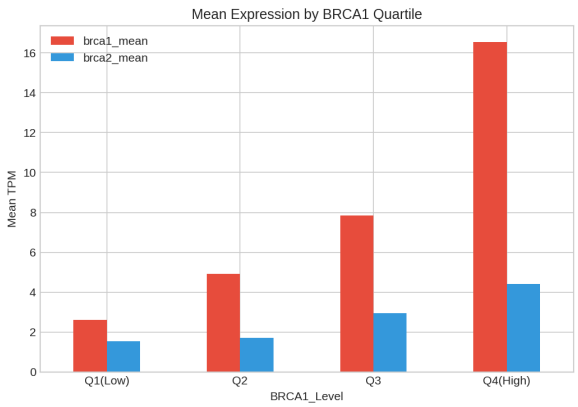

핵심 인사이트:

- BRCA1 발현이 높을수록 종양 비율이 급증: Q1(Low) **84.3%** → Q4(High) **99.7%**
- BRCA1과 BRCA2는 동조적으로 증가: BRCA1 Q4에서 BRCA2도 4.4 TPM (Q1의 2.8배)
- 이는 **DNA 손상 복구(DDR) 경로의 전반적 활성화**를 시사 — 유방암 종양에서 게놈 불안정성에 대한 보상적 반응으로 해석됩니다.

9. BRCA vs 다른 암종 비교

BRCA1/BRCA2 등 핵심 유전자의 발현량을 유방암 종양과 다른 23개 암종 종양 간 비교했습니다.

유전자	유방암 평균	타 암종 평균	비율	T-통계량	p-value
BRCA1	8.3622	7.2094	1.1599	10.2793	5.18e-24
BRCA2	2.8220	2.2927	1.2309	14.9828	1.58e-47
ESR1	221.3	13.0319	16.9792	49.9160	6.38e-299
PGR	33.2584	3.0471	10.9146	32.3727	5.46e-165
TP53	74.6446	68.0993	1.0961	8.6256	1.51e-17

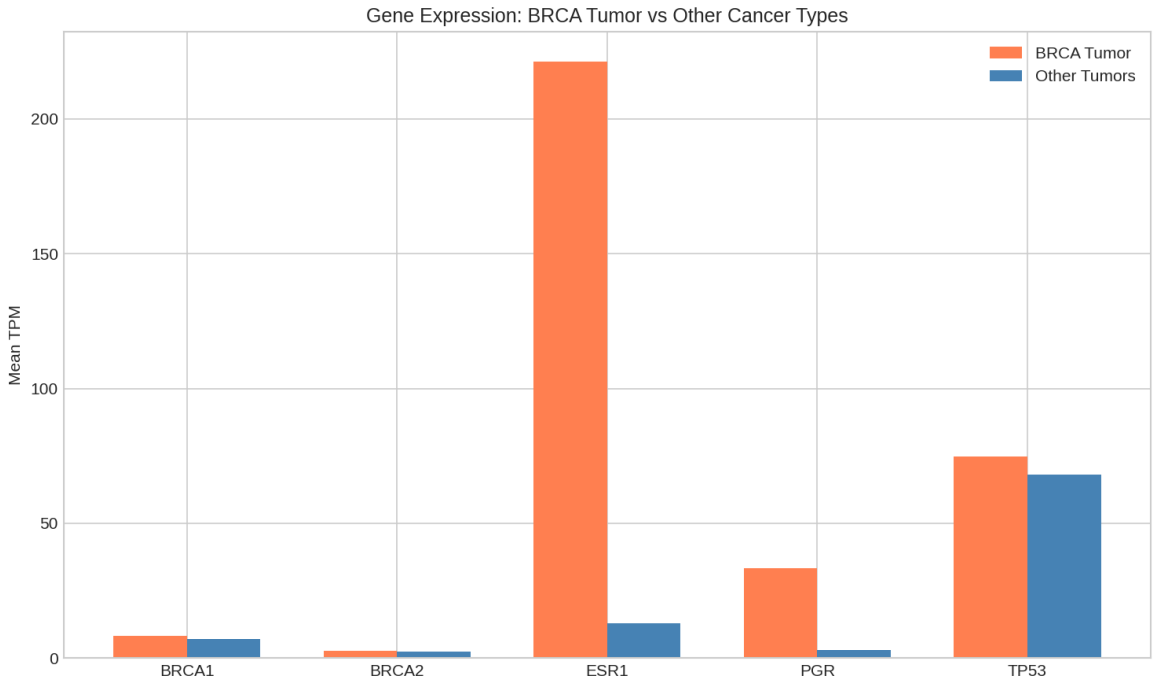

핵심 인사이트:

- **ESR1**: 유방암에서 타 암종 대비 **17.0배** 높은 발현 — 유방암 특이적 마커
- **PGR**: 유방암에서 **10.9배** 높은 발현 — 호르몬 수용체 양성 유방암의 특징
- **BRCA1**(1.16배), **BRCA2**(1.23배): 유방암에서 약간 높지만 차이가 크지 않음 → BRCA1/2는 유방암 특이적이라기보다 **범암종적(pan-cancer)** DDR 마커
- **TP53**(1.10배): 암종 간 차이 미미

10. 종합 요약 및 시사점

주요 발견사항

1. **BRCA 환자 1,218명 추출 성공**: TSS 코드 기반으로 종양 1,105명 + 정상 113명 식별
2. **BRCA1/BRCA2 과발현 확인**: 종양에서 각각 2.0배, 2.6배 증가 ($p \approx 0$)
3. **유방암 내 종양 구분력**: EGFR ($r=-0.477$)이 가장 강한 단일 피처, 이어서 MYC, PTEN, BRCA2 순
4. **전수조사 Top 유전자**: FIGF, CA4, TSLP 등 종양 미세환경 관련 유전자가 $|r|>0.7$로 지배적
5. **ESR1/PGR**: 유방암 특이적 발현 (타 암종 대비 10~17배) — 호르몬 수용체 서브타입 구분에 활용 가능
6. **TP53**: 유방암 내에서 종양/정상 구분력 없음 ($p=0.49$) — 발현량보다 돌연변이 여부가 중요
7. **BRCA1 발현 사분위**: Q4(고발현) 그룹의 99.7%가 종양 — BRCA1 발현량 자체가 유방암 바이오마커

향후 연구를 위한 제안

항목	제안
타겟 변수	Is_Tumor (종양/정상 분류) 또는 호르몬 수용체 서브타입 분류
피처 선택	전수조사 Top 20 + BRCA1, BRCA2, ESR1, PGR
서브타입 분석	ESR1/PGR 발현 기반 ER+/PR+ vs Triple Negative 분류
전처리	Log2(TPM+1) 변환, PIK3CA/EGFR 이상치 처리, TSS 기관 효과 보정
TDA 적용	BRCA1/BRCA2 + Top 20 유전자로 유방암 환자의 위상학적 구조 탐색

부록: 생성 파일 목록

파일명	유형	설명
00_BRCA_All_23368_Genes_Statistics.csv	CSV	BRCA 환자 전수조사 통계 (23,368개)
02_BRCA_TTest_Results.csv	CSV	주요 유전자 T-검정
03_BRCA_Point_Biserial.csv	CSV	Point-Biserial 상관
07_BRCA_Volcano_Plot.png	이미지	Volcano Plot
08_BRCA_Top20_Genes.csv	CSV	전수조사 Top 20 유전자
09_BRCA1_BRCA2_Detail.csv	CSV	BRCA1/BRCA2 상세 통계

파일명	유형	설명
09_BRCA1_Quartile_Analysis.csv	CSV	BRCA1 사분위 분석
10_BRCA_vs_OtherCancers.csv	CSV	유방암 vs 타 암종 비교