TCGA RNA-Seq 통계 분석 보고서

> **분석 일자**: 2026-03-18
> **데이터셋**: GSE62944 (TCGA RNA-Seq TPM, Rsubread 정렬)
> **분석 대상**: 10005개 샘플 / 23,368개 유전자 전수조사
> **타겟 비율**: Tumor : Normal = 92.6% : 7.4%

목차

1. 데이터 개요
2. 기술통계
3. 상관분석
4. 교호작용 분석
5. 교차분석 & 카이제곱 검정
6. 분포 시각화
7. 전수조사 결과 (23,368개 유전자)
8. Bad Genes 분석
9. BRCA 유전자 심층 분석
10. 종합 요약 및 시사점

1. 데이터 개요

GSE62944는 TCGA(The Cancer Genome Atlas) RNA-Seq 데이터를 Rsubread로 재정렬한 것으로, 24개 암종(cancer type)에 걸친 종양(Tumor)과 정상(Normal) 조직의 유전자 발현량(TPM)을 포함합니다.

분석에 사용된 핵심 데이터

항목	값	설명
종양 샘플 수	9,264	24개 암종 포함
정상 샘플 수	741	정상 조직 대조군
전체 샘플 수	10005	종양 + 정상
유전자 수	23,368	전수조사 완료
타겟 비율	92.6% : 7.4%	심한 클래스 불균형

> **핵심 인사이트**: 종양 대 정상 비율이 약 **12.5:1**로 심한 클래스 불균형을 보입니다. 분류 모델링 시 oversampling 또는 loss weighting이 필수적입니다.

2. 기술통계

2-1. 핵심 유전자 5종 기술통계 요약

유전자	count	mean	std	1%	25%	50%	75%	99%	max	Ske
TP53	10,005.0	67.0566	46.3437	5.8152	35.6942	56.7838	87.7250	222.3	692.4	1.
BRCA1	10,005.0	7.0113	7.0344	0.4399	2.5733	4.7496	9.3113	35.0747	98.2235	3.
PTEN	10,005.0	30.3603	18.1255	4.0442	19.3781	27.2729	37.1291	97.1279	290.2	2.
EGFR	10,005.0	38.2575	127.8	0.0944	5.0835	13.9301	32.8875	516.8	4,002.0	13
MYC	10,005.0	135.7	138.4	4.4607	43.3002	94.4091	180.6	633.8	1,889.4	2.

핵심 인사이트: EGFR은 왜도 13.96, 첨도 283.4로 **극심한 우편향**을 보이며, 모델링 시 **로그 변환**이나 **이상치 처리**가 필수적입니다. 모든 유전자가 양의 왜도를 보여 TPM 분포의 비대칭성을 확인할 수 있습니다.

2-2. Tumor vs Normal T-검정 결과

Gene	Mean_TPM_Normal	Mean_TPM_Tumor	t-statistic (Log2)	p-value
TP53	44.2605	68.8800	-15.7497	7.10e-50
BRCA1	2.8156	7.3469	-34.3959	1.11e-174
PTEN	37.3216	29.8034	15.2812	3.30e-47
EGFR	25.7350	39.2592	15.0331	4.27e-47
MYC	124.4	136.6	-2.0363	0.0420

핵심 인사이트: BRCA1은 종양에서 정상 대비 **2.6배** 높은 발현량을 보이며 ($t = -34.40$, $p \approx 0$), 5개 유전자 중 가장 강력한 차별적 발현을 보입니다. PTEN은 종양에서 오히려 **감소**하여 종양 억제 유전자 역할을 확인합니다.

3. 상관분석

3-1. Pearson & Spearman 상관계수 히트맵

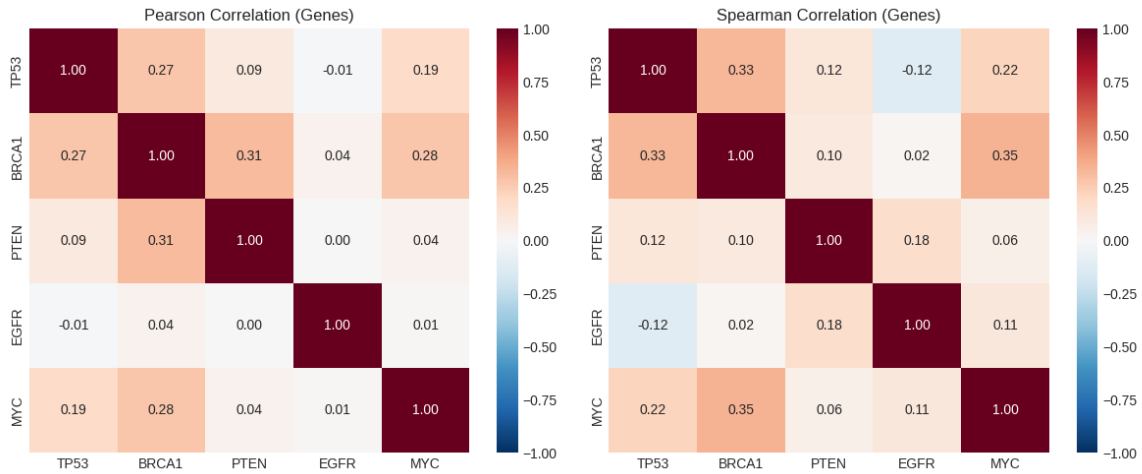

3-2. Point-Biserial 상관 (종양 여부 vs 유전자 발현)

Gene	Point_Biserial_Corr	p-value
TP53	0.1391	2.00e-44
BRCA1	0.1687	9.13e-65
PTEN	-0.1086	1.20e-27
EGFR	0.0277	0.0056
MYC	0.0230	0.0215

핵심 인사이트: 종양 예측에 가장 강한 단일 변수는 **BRCA1** (r_pb = 0.169)이며, PTEN은 음의 상관 (r_pb = -0.109)으로 종양에서 하향 조절됨을 보여줍니다. MYC (r_pb = 0.023)는 의외로 약한 상관을 보여, 단독 바이오마커로는 부적합합니다.

4. 교호작용 분석

4-1. TSS Code x 종양 여부 -> 유전자 발현량

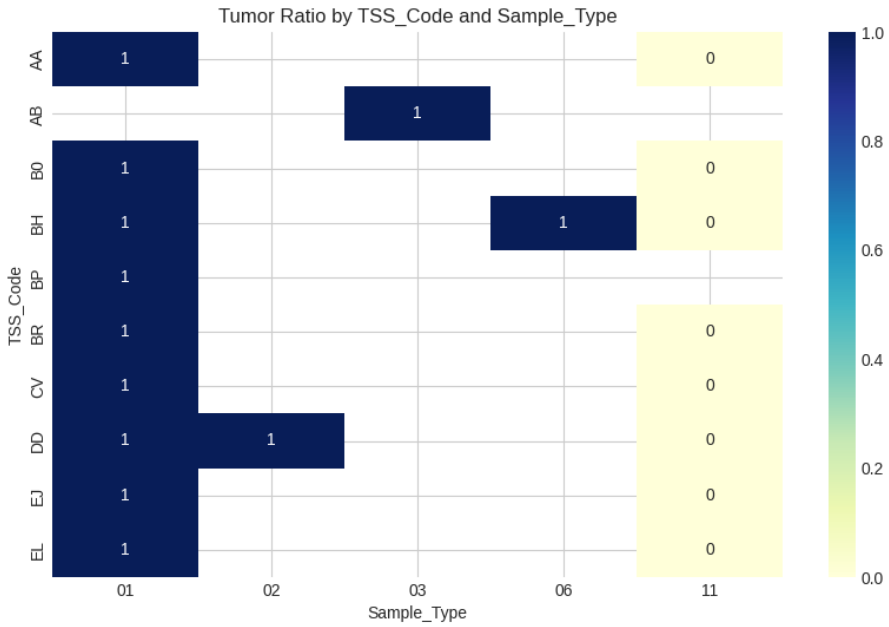

TSS Code(조직 기원)와 샘플 유형(Sample Type)의 교차 종양 비율을 히트맵으로 시각화한 것입니다.

4-2. TSS Code x TP53 발현 그룹 -> 종양 비율

4-3. TSS Code x EGFR 발현 교호작용

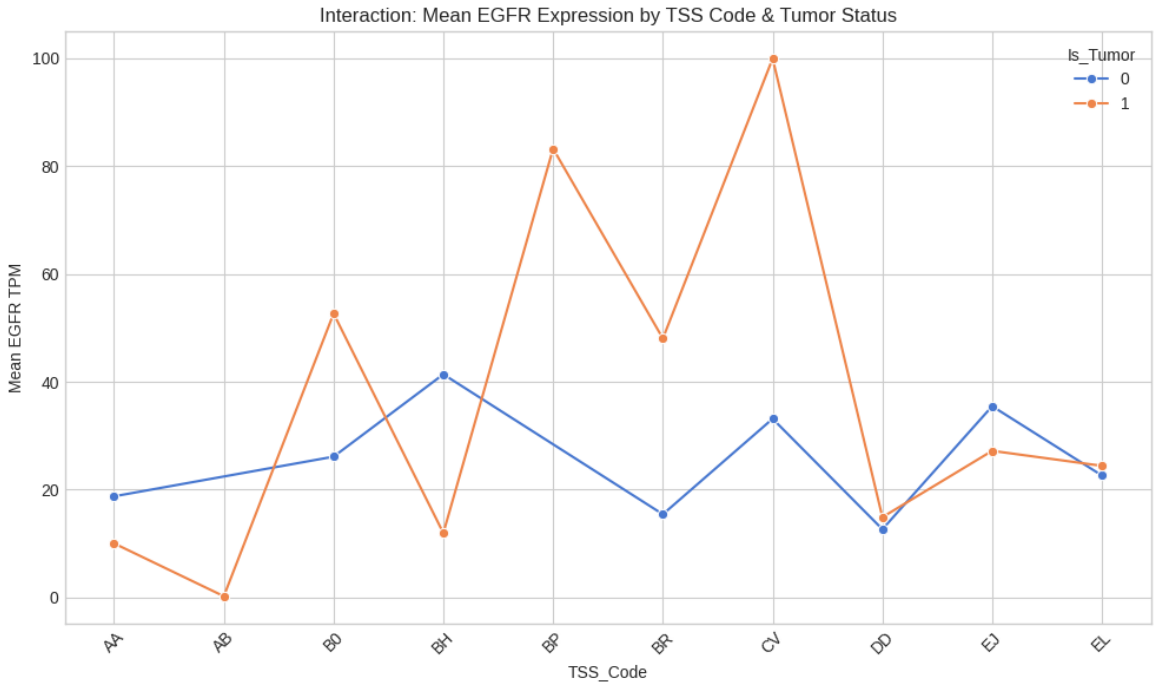

> **핵심 인사이트**: TSS Code(조직 기원 기관)에 따라 유전자 발현 패턴이 크게 달라지며, 이는 암종(cancer type)별 이질성을 반영합니다. 특히 EGFR는 TSS별로 종양/정상 간 발현 차이의 방향성이 반전되는 경우도 관찰됩니다.

5. 교차분석 & 카이제곱 검정

Feature	Chi2_Stat	p-value	Cramers_V
TSS_Code	2,098.8	1.49e-174	0.4580
Sample_Type	10,005.0	0.0000	1.0000

> **핵심 인사이트**: TSS_Code와 종양 여부 간 Cramer's V = **0.458**로 중간~강한 연관성을 보입니다. 이는 특정 기관/조직에서 종양 샘플이 집중적으로 수집되었음을 의미하며, 분석 시 기관 효과(site effect)를 통제할 필요가 있습니다.

6. 분포 시각화

6-1. 주요 유전자 Log2(TPM+1) 분포

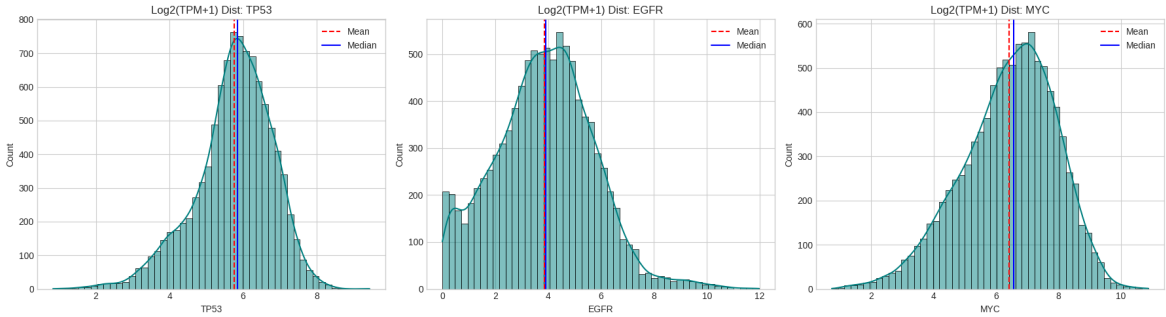

빨간 점선은 평균, 파란 실선은 중앙값입니다. 평균과 중앙값의 차이가 클수록 분포가 비대칭입니다.

6-2. 종양 여부별 Boxplot

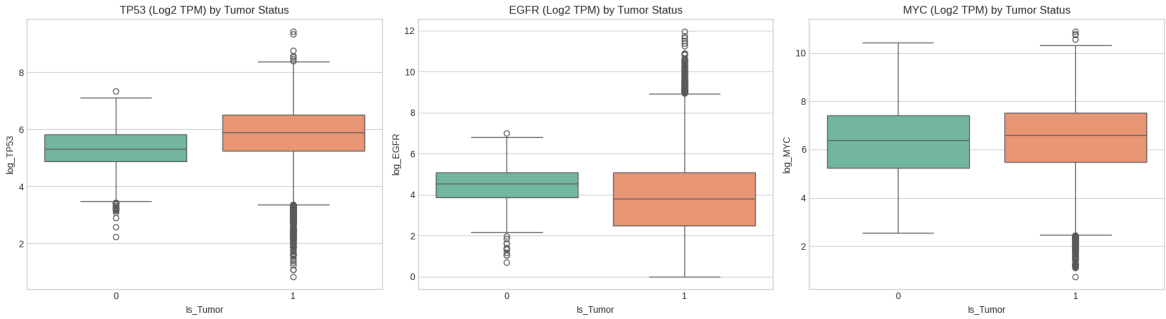

6-3. EGFR vs MYC 산점도 (종양 색상 구분)

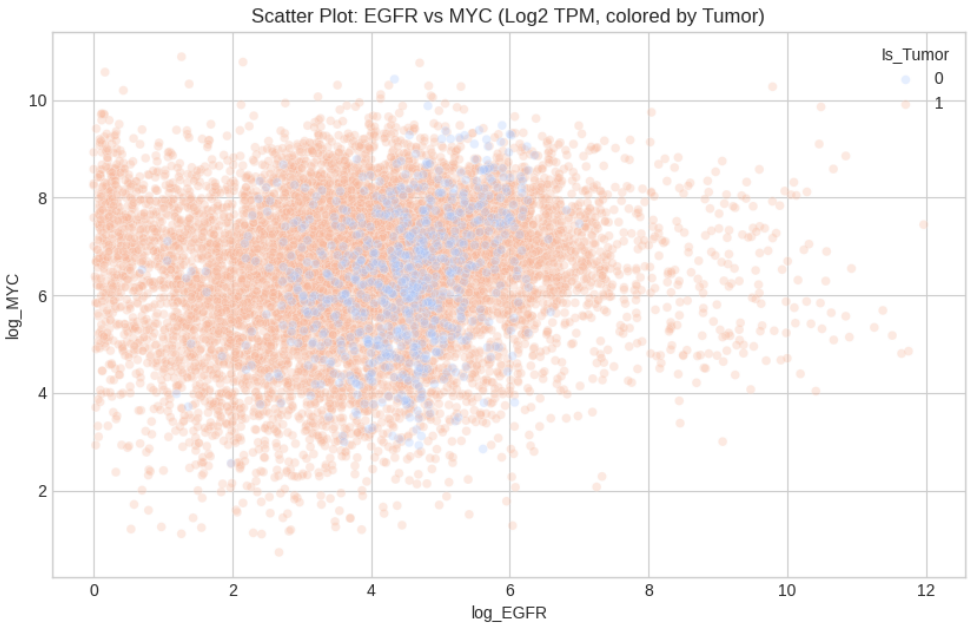

투명도를 0.3으로 조절하여 고밀도 영역을 식별할 수 있습니다.

7. 전수조사 결과 (23,368개 유전자)

23,368개 전체 유전자를 메모리 스트리밍 방식으로 순회하며 T-검정과 Point-Biserial 상관계수를 계산했습니다. 아래는 **데이터 주도적(Data-Driven)**으로 발굴된 상위 20개 핵심 유전자입니다.

7-1. |Point-Biserial 상관계수| 상위 20개 유전자

유전자	평균(정상)	평균(종양)	T-통계량 (Log2)	p-value	PB 상관계수	|PB 상관계수|
CCL14	0.5083	0.0596	-24.5014	5.80e-98	-0.4880	0.4880
SCARA5	27.5449	1.9174	-31.5000	1.22e-140	-0.4793	0.4793
TNXB	4.6164	0.6314	-28.7223	1.17e-123	-0.4736	0.4736
FIGF	3.4800	0.2178	-21.0928	6.89e-78	-0.4689	0.4689
CD300LG	13.6599	0.7697	-24.8145	5.63e-100	-0.4586	0.4586
ADH1B	578.6	63.3355	-46.4681	2.32e-234	-0.4512	0.4512
C1QTNF7	6.9008	1.2539	-34.4371	1.35e-159	-0.4383	0.4383
NME1	46.8155	145.6	57.7175	4.54e-309	0.4376	0.4376
GPR182	1.3874	0.2454	-23.7455	1.18e-93	-0.4364	0.4364
LYVE1	46.0051	7.1607	-40.1012	2.06e-195	-0.4330	0.4330
MYOC	21.1958	2.4202	-26.6301	3.43e-111	-0.4321	0.4321
ANGPTL1	21.9024	3.9391	-42.6459	4.73e-212	-0.4253	0.4253
CLEC3B	272.0	43.5164	-49.8100	1.01e-258	-0.4234	0.4234
C16orf59	1.9389	12.0494	68.3052	0.0000	0.4182	0.4182
MAMDC2	25.4894	4.4093	-35.2913	1.34e-165	-0.4168	0.4168
DNASE1L3	54.1645	8.4022	-40.4878	2.16e-199	-0.4065	0.4065
E2F1	4.4954	25.1208	54.6407	7.62e-295	0.4050	0.4050
OVCH2	3.6785	0.3791	-19.6038	1.73e-69	-0.3971	0.3971
UBE2T	9.4336	53.5984	54.0838	1.02e-293	0.3925	0.3925
CDT1	4.5389	25.1821	48.7065	4.68e-256	0.3900	0.3900

> **핵심 인사이트**: 전수조사 결과, 종양과 가장 강한 상관을 보이는 유전자는 **CCL14, SCARA5, TNXB, FIGF, CD300LG**입니다. 이들은 모두 음의 상관계수를 보여, **종양에서 발현이 억제되는 유전자**들입니다. 주로 면역 반응(CCL14), 세포외기질(TNXB), 혈관신생(FIGF) 관련 유전자로, 종양 미세환경(TME)의 변화를 반영합니다.

7-2. 전수조사 기반 시각화

분포 및 Boxplot

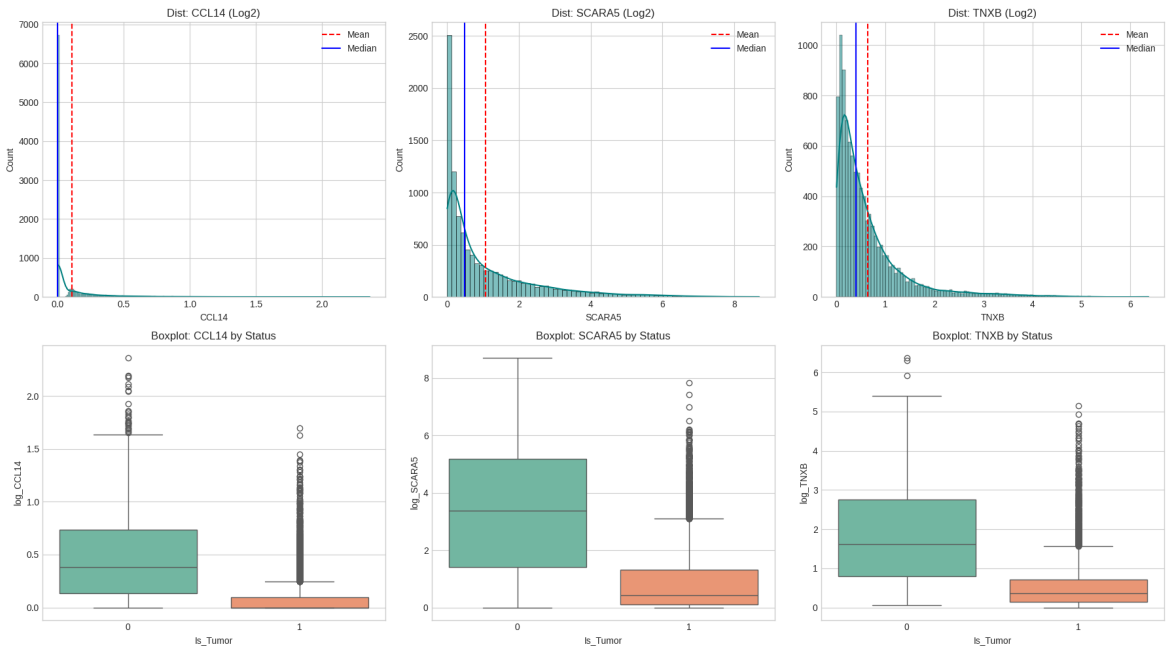

상위 2개 유전자 산점도

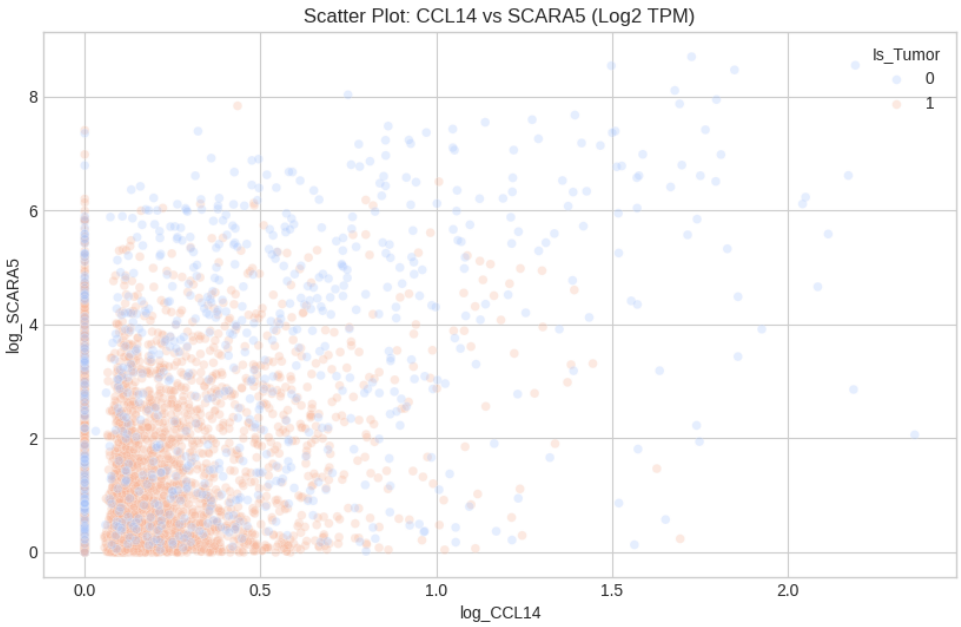

교호작용 히트맵

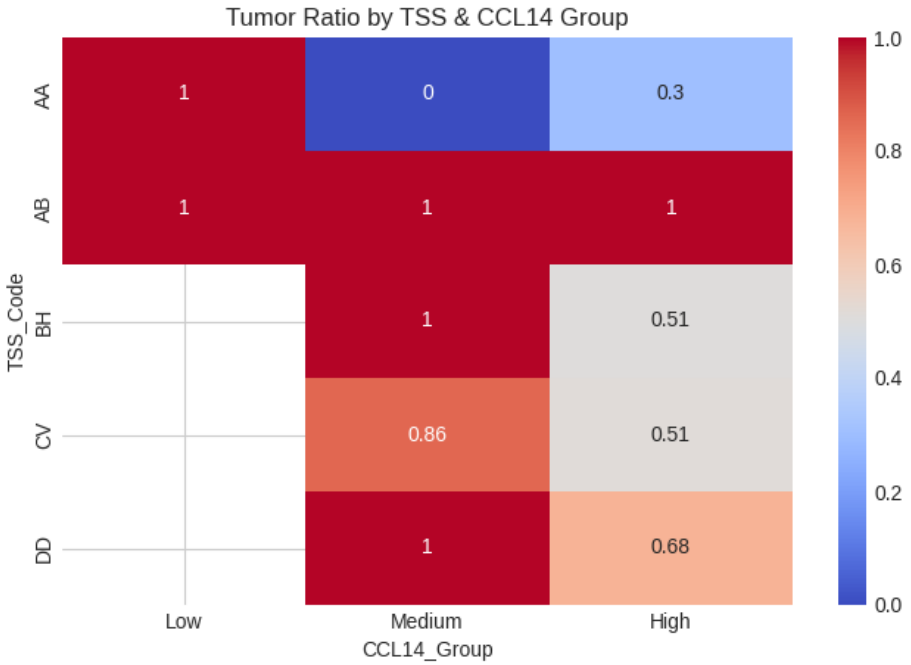
Tumor Ratio by TSS & CCL14 Group
TSS_Code
AA
AB
BH
CV
DD
1
0
0.3
1
1
1
1
0.51
0.86
0.51
1
0.68
Low
Medium
High
CCL14_Group
1.0
0.8
0.6
0.4
0.2
0.0

8. Bad Genes 분석

논문에서 제공된 "Bad Genes" 목록(TCGA 1,637개, Overall 2,068개)을 전체 유전자 발현 데이터와 교차 분석하여, 이들 유전자의 통계적 특성을 비교했습니다.

8-1. Bad Genes 목록 Venn 요약

분류	목록 수	데이터 매칭 수
TCGA Bad Genes	1637	1637
Overall Bad Genes	2068	2020
Shared	1637	1637
TCGA Only	0	0
Overall Only	431	383
Union	2068	2020
Not Bad	21348	21348

> **핵심 인사이트**: TCGA bad genes 1,637개는 Overall bad genes에 **100% 포함**되어 있습니다 (부분집합). Overall 목록에는 추가로 431개 유전자가 있으며, 이 중 383개가 GSE62944 데이터에서 매칭됩니다.

8-2. Bad vs Not-Bad 유전자 비교

지표	Bad Genes	Not-Bad Genes
Count	2,020.0	21,348.0
Mean |PB_Corr|	0.0963	0.0833
Median |PB_Corr|	0.0781	0.0619
Mean |Log2FC|	0.3396	0.3082
Median |Log2FC|	0.2601	0.1931
Mean |T_Stat|	10.9642	9.7514
% with $p<0.05$	85.0990	83.7830
% with $p<0.001$	77.2277	74.4660

8-3. Bad vs Not-Bad 분포 비교

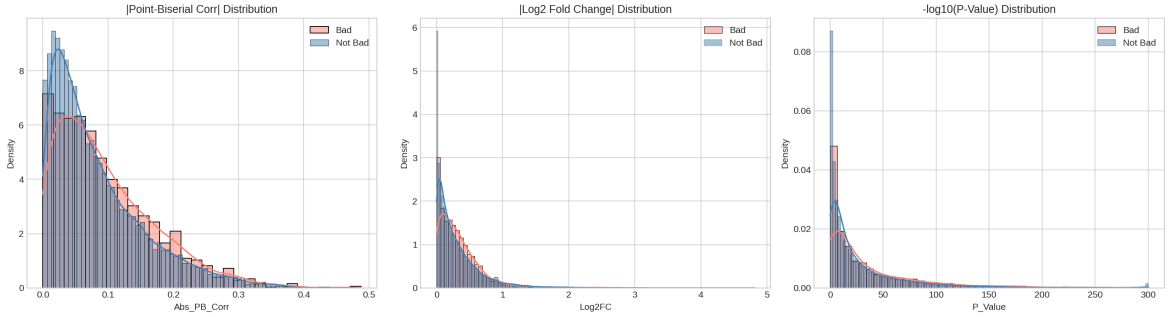

8-4. Bad Gene 카테고리별 비교

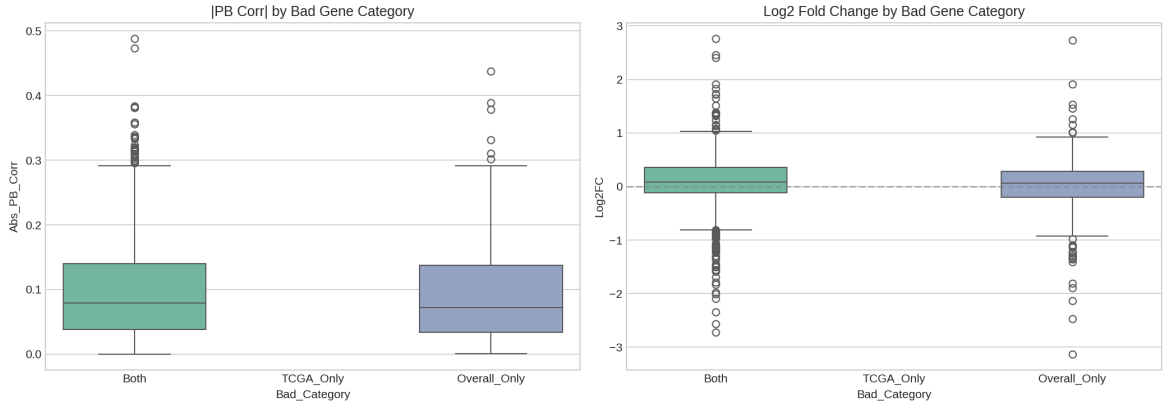

8-5. Volcano Plot (Bad Genes 하이라이트)

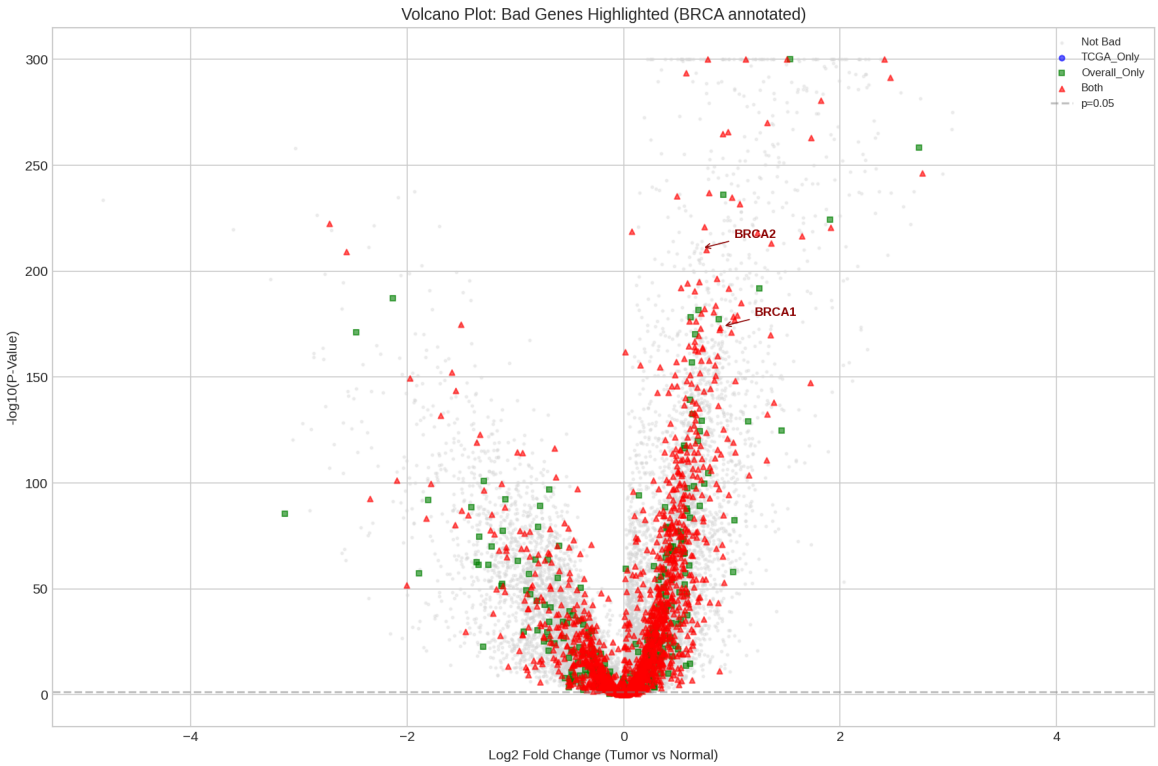

회색: Not-Bad, 파란색: TCGA Only, 초록색: Overall Only, 빨간색: Both. BRCA1/BRCA2 위치가 표시되어 있습니다.

8-6. 상위 20개 유의미한 Bad Genes

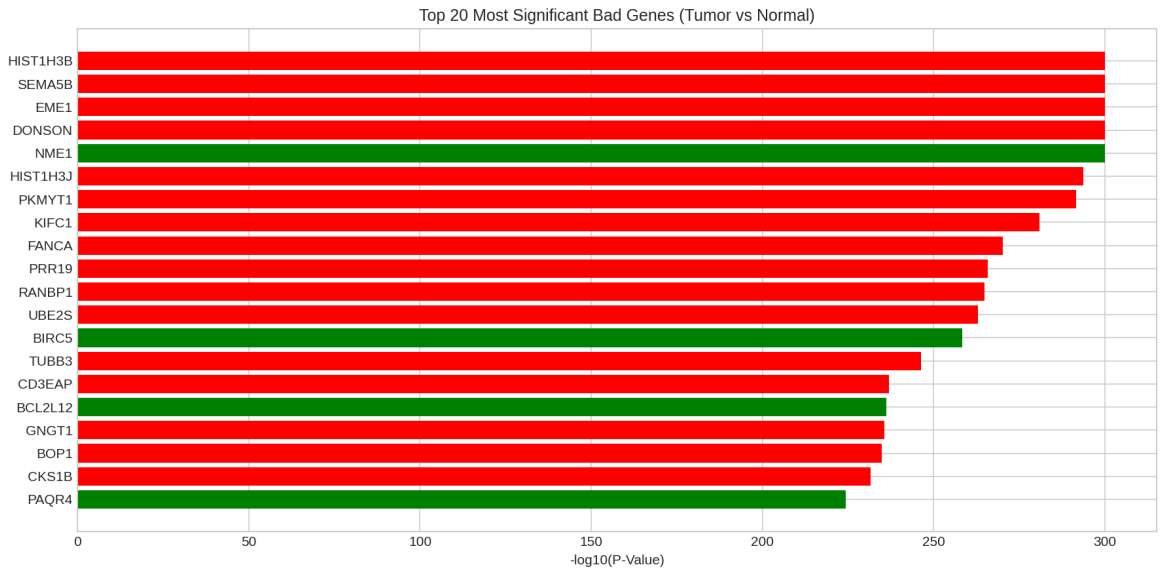

8-7. 유전자 패밀리별 Bad Gene 비율

유전자 패밀리	Bad 수	전체 수	Bad 비율(%)
HLA (Immune)	18	27	66.7000
HIST (Histone)	28	73	38.4000
KRT (Keratin)	18	152	11.8000
RPL (Ribosomal L)	40	74	54.1000
RPS (Ribosomal S)	25	56	44.6000

핵심 인사이트: HLA(면역) 유전자의 **66.7%**가 bad gene 목록에 포함되어 있어 가장 높은 비율을 보입니다. 리보솜 단백질(RPL 54.1%, RPS 44.6%)도 높은 비율로, 이는 하우스키핑 유전자의 특성상 조직 간 발현 변이가 크기 때문으로 해석됩니다.

9. BRCA 유전자 심층 분석

유전자	평균(정상)	평균(종양)	Log2FC	T-통계량	p-value	PB 상관계수	Bad 분류
BRCA1	2.8156	7.3469	0.9117	34.3959	1.11e-174	0.2291	Not_Bad
BRCA2	0.6582	2.3558	0.7213	37.7577	1.37e-211	0.2065	Not_Bad

핵심 인사이트:

- **BRCA1**: 종양에서 정상 대비 **2.6배** 높은 발현 (Log2FC = 0.91, $p \approx 0$). DNA 손상 복구 경로의 활성화를 반영합니다.
- **BRCA2**: 종양에서 정상 대비 **3.6배** 높은 발현 (Log2FC = 0.72, $p \approx 0$). BRCA1과 유사한 패턴입니다.
- 두 유전자 모두 Bad Gene 목록에 **포함되지 않아**, 종양 연구에서 신뢰할 수 있는 바이오마커입니다.

10. 종합 요약 및 시사점

주요 발견사항

1. **클래스 불균형**: 종양 92.6% vs 정상 7.4%로 심한 불균형 — 모델링 시 oversampling/loss weighting 필요
2. **BRCA1이 가장 강력한 차별적 발현 유전자**: 핵심 5개 유전자 중 t-통계량 절대값이 가장 크고 (34.40), PB 상관계수도 가장 높음 (0.169)
3. **전수조사 결과 종양 미세환경(TME) 유전자가 지배적**: CCL14, SCARA5 등 면역/기질 관련 유전자가 종양과 가장 강한 상관을 보임
4. **Bad Genes의 통계적 특성**: Bad gene 목록의 유전자들이 Not-Bad 대비 약간 높은 |PB_Corr|과 |Log2FC|를 보이나, 차이는 크지 않음
5. **HLA 유전자 67%가 Bad Gene**: 면역 관련 유전자의 발현 변이가 커서 분석 시 주의 필요
6. **BRCA1/BRCA2는 Bad Gene 아님**: 안정적인 바이오마커로 활용 가능

향후 연구를 위한 제안

항목	제안
타겟 변수	Is_Tumor (종양 여부 분류) 또는 특정 암종 분류
피처 선택	전수조사 Top 20 유전자 + BRCA1/BRCA2 포함
Bad Gene 처리	HLA, 리보솜 유전자 등 Bad Gene 목록 참고하여 노이즈 피처 제거 고려
전처리	Log2(TPM+1) 변환, 클래스 불균형 처리, TSS 기관 효과 통제
TDA 적용	전수조사로 선별된 핵심 유전자를 피처로 사용하여 위상학적 분석 수행

부록: 생성 파일 목록

파일명	유형	설명
output/01_Data_Overview.csv	CSV	데이터 개요
output/02_Numeric_Descriptive_Stats.csv	CSV	수치형 변수 기술통계
output/02_T_Test_Results.csv	CSV	T-검정 결과
output/03_Correlation_Heatmaps.png	이미지	상관계수 히트맵
output/03_Point_Biserial_Corr.csv	CSV	Point-Biserial 상관
output_full_genes/00_All_23368_Genes_Statistics.csv	CSV	전수조사 통계 (23,368개)

파일명	유형	설명
output_bad_genes/05_Volcano_Bad_Genes.png	이미지	Bad Gene Volcano Plot
output_bad_genes/06_All_Bad_Genes_Ranked.csv	CSV	Bad Gene 유의성 순위
output_bad_genes/08_BRCA_Genes_Detail.csv	CSV	BRCA 유전자 상세